Language Translation and Code-Breaking

Kevin Knight
Information Sciences Institute
University of Southern California

joint work with

Beáta Megyesi, Christiane Schaefer (Uppsala) Sujith Ravi (USC)

CUNY

February 2012

Machine Translation

美国关岛国际机场及其办公室均接获一名自称沙地阿拉伯富商拉登等发出的电子邮件,威胁将会向机场等公众地方发动生化袭击後,关岛经保持高度戒备。

Kowane mutum na da hakkin ya sami yancin yin tunani da na sanin yakamata da na bin addini; saboda haka yana da yancin sake addini ko ra'ayin da ya bada gaskiya gare shi, da kuma yancin nuna addininsa ko ra'ayinsa, shi daya ko a cikin taro kuma a fili ko a boye ta hanyar koyarwa ko yin ibada, ko bauta wa abin da ya bada gaskiya gare shi da yin abubuwan da abin da yake bauta wa din ya nuna masa.

Machine Translation

美国关岛国际机场及其办公室均接获一名自称沙地阿拉伯富商拉登等发出的电子邮件,威胁将会向机场等公众地方发动生化袭击後,关岛经保持高度戒备。



The U.S. island of Guam is maintaining a high state of alert after the Guam airport and its offices both received an e-mail from someone calling himself the Saudi Arabian Osama bin Laden and threatening a biological/chemical attack against public places such as the airport.

Kowane mutum na da hakkin ya sami yancin yin tunani da na sanin yakamata da na bin addini; saboda haka yana da yancin sake addini ko ra'ayin da ya bada gaskiya gare shi, da kuma yancin nuna addininsa ko ra'ayinsa, shi daya ko a cikin taro kuma a fili ko a boye ta hanyar koyarwa ko yin ibada, ko bauta wa abin da ya bada gaskiya gare shi da yin abubuwan da abin da yake bauta wa din ya nuna masa.



Everyone has the right to freedom of thought, conscience and religion; this right includes freedom to change his religion or belief, and freedom, either alone or in community with others and in public or private, to manifest his religion or belief in teaching, practice, worship and observance.

Statistical Machine Translation

"When I look at an article in Russian, I say: this is really written in English, but it has been coded in some strange symbols. I will now proceed to decode." -- Warren Weaver (1947)

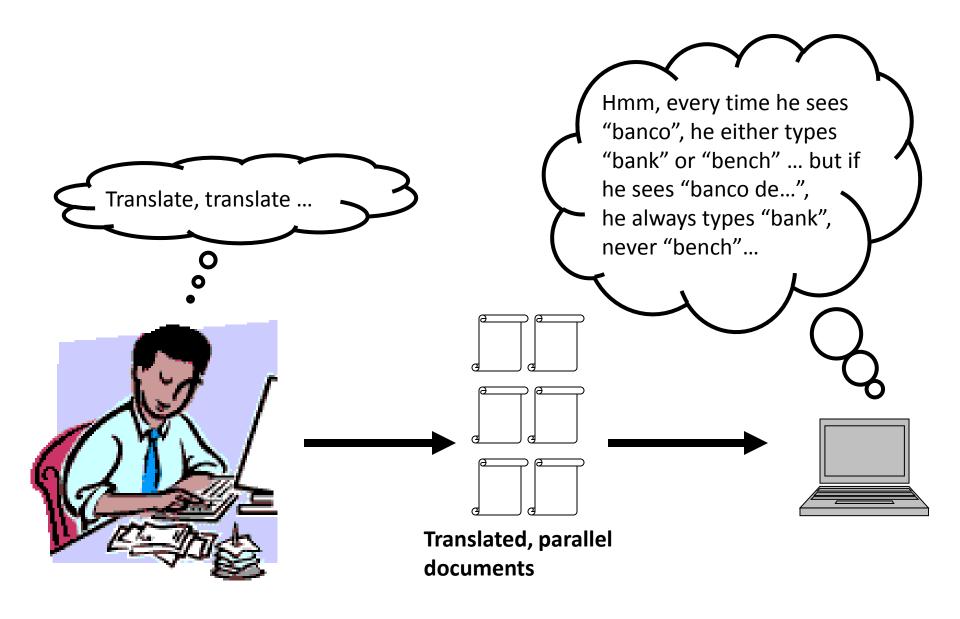


OUR HERO

Weaver saw a colleague decoding intercepts into Turkish, without "knowing" Turkish.

... maybe a computer could translate into English without "knowing" English?

Statistical Machine Translation



Parallel Corpus

12 English sentences in English and Spanish.

1a. Garcia and associates .1b. Garcia y asociados .	7a. the clients and the associates are enemies .7b. los clients y los asociados son enemigos .
2a. Carlos Garcia has three associates .2b. Carlos Garcia tiene tres asociados .	8a. the company has three groups . 8b. la empresa tiene tres grupos .
3a. his associates are not strong . 3b. sus asociados no son fuertes .	9a. its groups are in Europe . 9b. sus grupos estan en Europa .
4a. Garcia has a company also .4b. Garcia tambien tiene una empresa .	10a. the modern groups sell strong pharmaceuticals . 10b. los grupos modernos venden medicinas fuertes .
5a. its clients are angry .5b. sus clientes estan enfadados .	11a. the groups do not sell zenzanine . 11b. los grupos no venden zanzanina .
6a. the associates are also angry .6b. los asociados tambien estan enfadados .	12a. the small groups are not modern .12b. los grupos pequenos no son modernos .

Parallel Corpus

12 English sentences in Centauri and Arcturan.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat .
3a. erok sprok izok hihok ghirok.	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat .	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat .

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat .	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat.
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat .

1a. ok-voon ororok sprok .	7a. lalok <mark>farok</mark> ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok.	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat.
5a. wiwok <mark>farok</mark> izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat.
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat .
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat .
3a. erok sprok izok hihok ghirok.	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat.
5a. wiwok <mark>farok</mark> izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat .	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok.	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat .	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok <mark>crrrok</mark> hihok yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok <mark>hihok</mark> ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok crrrok <mark>hihok</mark> yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat.
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok <mark>hihok</mark> mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok <mark>yorok</mark> ghirok clok .
4b. at-voon krat pippat sat lat .	10b. wat nnat gat mat bat hilat .
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok <mark>yorok</mark> z anzanok .
5b. totat jjat quat cat .	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp.
4a. ok-voon anok drok brok jok.	10a. lalok mok nok yorok ghirok <mark>clok .</mark>
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat .
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat .	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
ou. Iulok sprok izok jok stok.	12u. mok futok nok izok iniok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat .	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok.	10a. lalok mok nok yorok ghirok <mark>clok .</mark>
4b. at-voon krat pippat sat lat .	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok.
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat.
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok .	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat.	9b. totat nnat quat oloat at-yurp .
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok .
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat.
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat .
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat .	12b. wat nnat forat arrat vat gat .

1a. ok-voon ororok sprok .	7a. lalok farok ororok lalok sprok izok enemok .
1b. at-voon bichat dat.	7b. wat jjat bichat wat dat vat eneat.
2a. ok-drubel ok-voon anok plok sprok.	8a. lalok brok anok plok nok .
2b. at-drubel at-voon pippat rrat dat.	8b. iat lat pippat rrat nnat.
3a. erok sprok izok hihok ghirok.	9a. wiwok nok izok kantok ok-yurp .
3b. totat dat arrat vat hilat.	9b. totat nnat quat oloat at-yurp
4a. ok-voon anok drok brok jok .	10a. lalok mok nok yorok ghirok clok process of
4b. at-voon krat pippat sat lat.	10b. wat nnat gat mat bat hilat. elimination
5a. wiwok farok izok stok .	11a. lalok nok crrrok hihok yorok zanzanok .
5b. totat jjat quat cat.	11b. wat nnat arrat mat zanzanat.
6a. lalok sprok izok jok stok .	12a. lalok rarok nok izok hihok mok .
6b. wat dat krat quat cat.	12b. wat nnat forat arrat vat gat.

Statistical Machine Translation

1999

- one page per day, low quality
- limited domains, languages
- no commercial offerings

2011

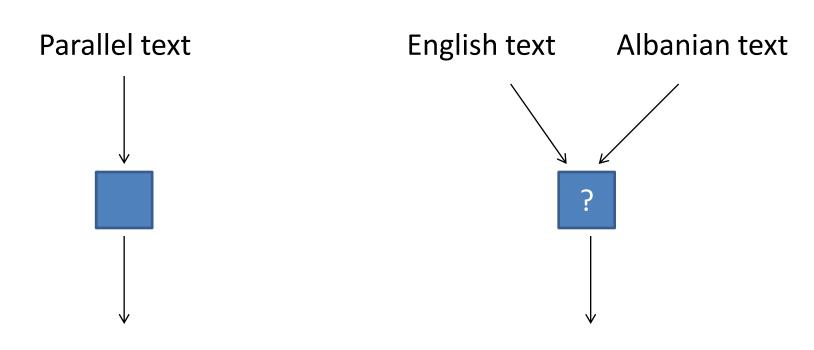
- fast, 50+ languages
- quality much improved
- products for business,
 intelligence, end users

أعلن الرئيس الصومالي شريف شيخ أحمد أثناء زيارة لمواقع للقوات الحكومية والأفريقية في حي هودن في مقديشو أن الحلن المعسكرية الحالية "لن تتوقف حتى تتحرر الصومال من الشباب والقاعدة".



Somali President Sharif Sheikh Ahmed during a visit to sites of government forces and African in the district of Howden in Mogadishu that the current military campaign "will not stop until Somalia is liberated from the youth and al-Qaeda."

Learn Translation Knowledge from Non-Parallel Text?



Translation model

Translation model

German Enigma Machines (1926-45)

Substitution system

 $N \rightarrow 1$

Substitution table **changes** with every keystroke:

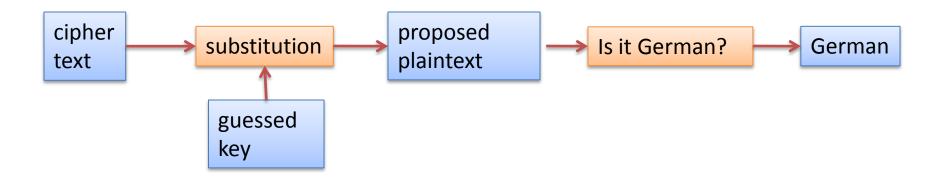
NNN → JTE

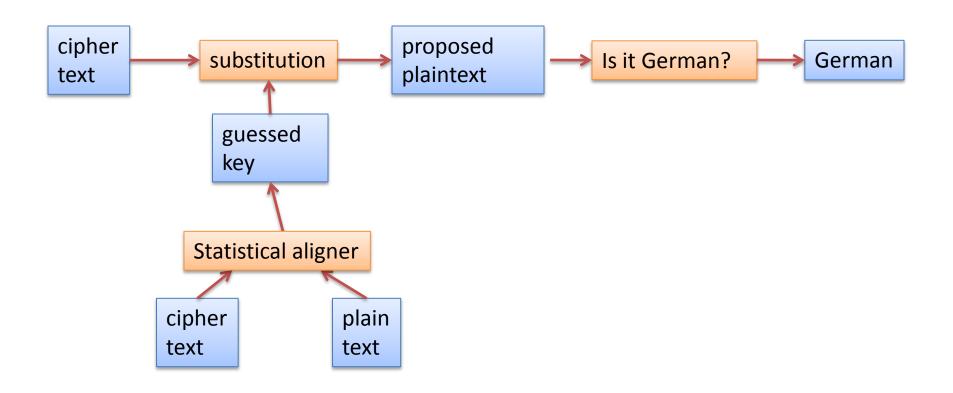
Flattens out ciphertext letter distributions.

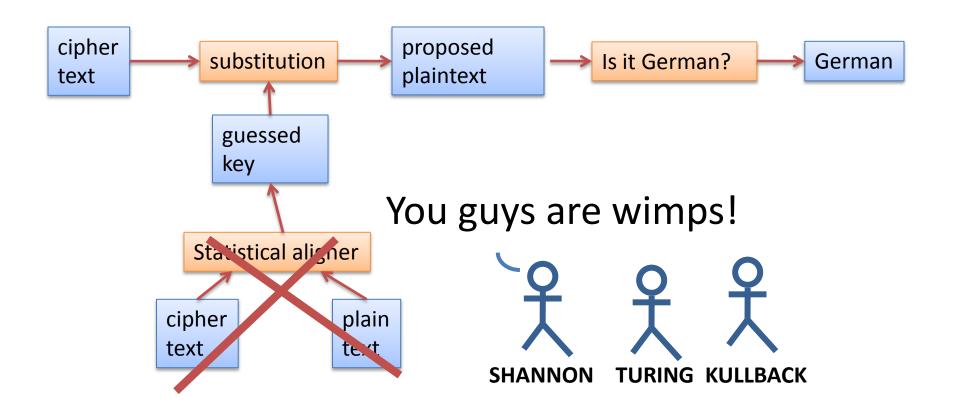
Secret key = initial rotor ordering and settings

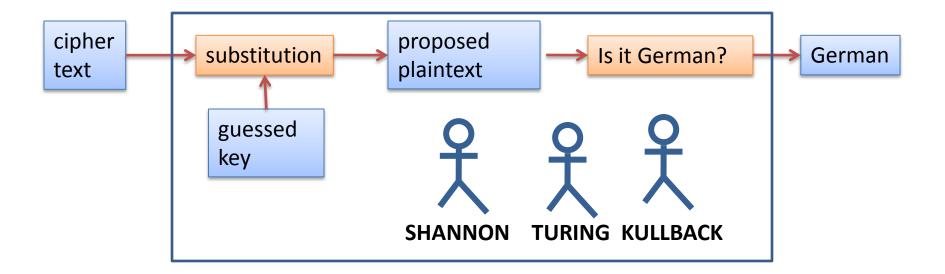
Reversible behavior

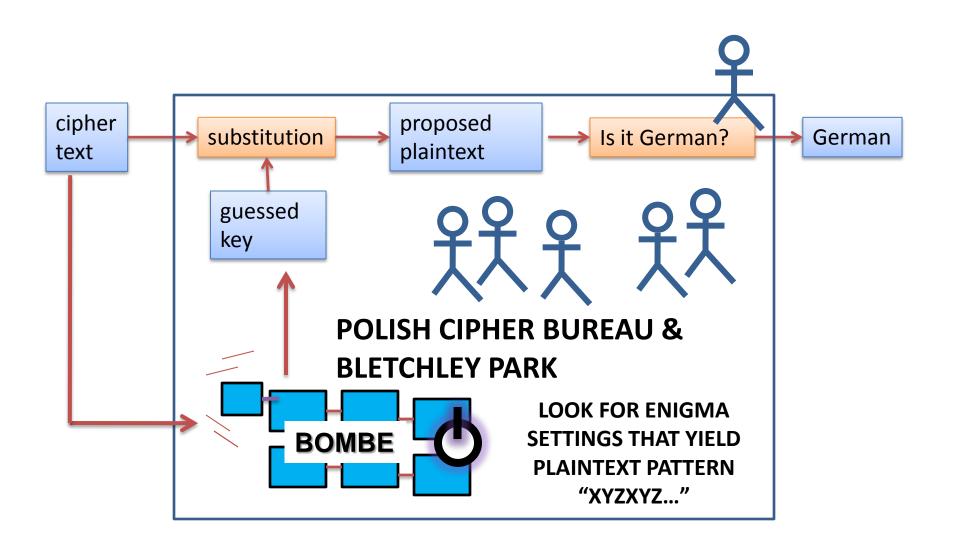
 $NNN \rightarrow JTE \rightarrow NNN$

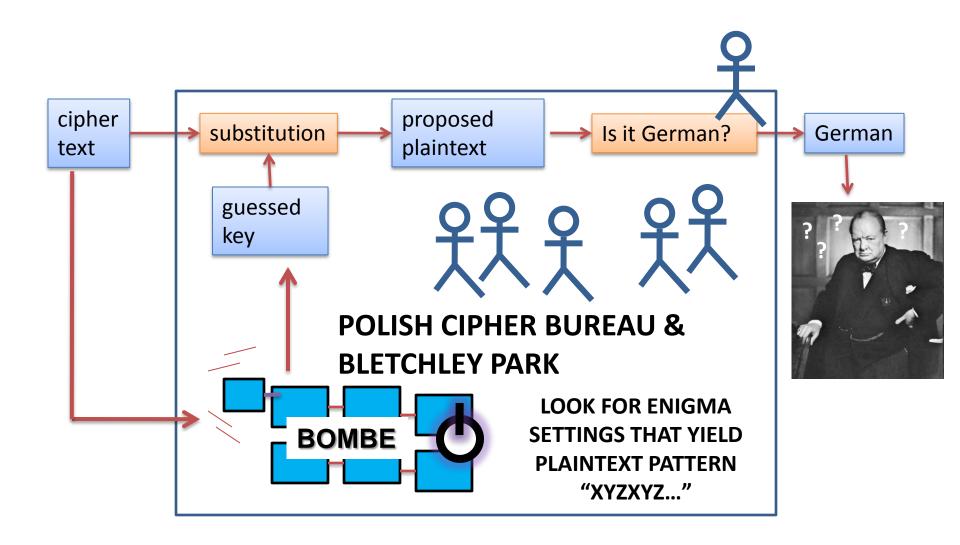










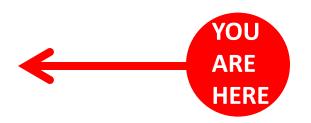


What's the Plan for This Talk?

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography

What's the Plan for This Talk?

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography



Letter Substitution Cipher

Encipherment key:

PLAIN: ABCDEFGHIJKLMNOPQRSTUVWXYZ

CIPHER: PLOKMIJNUHBYGVTFCRDXESZAQW

• Plaintext: **HELLO WORLD** . . .

• Ciphertext: **NMYYT ZTRYK** . . .

- Key itself doesn't change: "simple substitution"
- What key, if applied to the ciphertext, would yield sensible plaintext?

KDCY LQZKTLJKX CY MDBCYJQL: "TR

HYD FKXC, FQ MKX RLQQIQ HYDL

MKL DXCTW RDCDLQ JQMNKXTMB

PTBMYEQL K FKH CY LQZKTL TC."

KDCY LQZKTLJKX CY MDBCYJQL: "TR В 3 HYD FKXC, FQ MKX RLQQIQ HYDL G MKL DXCTW RDCDLQ JQMNKXTMB L 10 M 6 N 1 0 P 1 Q 10 PTBMYEQL K FKH CY LQZKTL TC." R 3 S Т 7 U V X 5

```
KDCY LQZKTLJKX CY MDBCYJQL:
HYD FKXC, FQ MKX RLQQIQ HYDL
MKL DXCTW RDCDLQ JQMNKXTMB
PTBMYEQL K FKH CY LQZKTL TC."
                                  U
```

```
KDCY LQZKTLJKX CY MDBCYJQL: "TR
HYD FKXC, FQ MKX RLQQIQ HYDL
                                     10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                       ##
PTBMYEQL K FKH CY LQZKTL TC."
                                       ### V
                                    U
```

V

```
a
        . a
             . a
KDCY LQZKTLJKX CY MDBCYJQL: "TR
                a
HYD FKXC, FQ MKX RLQQIQ HYDL
 a
                        . a
                                        10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                       L 10 ##
         a .a.
                        . a
PTBMYEQL K FKH CY LQZKTL TC."
                                          ### V
                                       U
                                          ### V
```

```
e.a .a
                          . e
KDCY LQZKTLJKX CY MDBCYJQL: "TR
          .e a .ee.e .
HYD FKXC, FQ MKX RLQQIQ HYDL
 а
                e .e .a
                                     10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                    L 10 ##
      .e a .a.
                    e.a
PTBMYEQL K FKH CY LQZKTL TC."
                                     т 7 ### ∨
                                     U
      didn't create "ae"
```

```
e.ao .a
                           . е
KDCY LQZKTLJKX CY MDBCYJQL: "TR
          .e a .ee.e .
HYD FKXC, FQ MKX RLQQIQ HYDL
 а
               e .e .a o
                                      K 10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                      L 10 ##
                   e.ao
      .e a .a.
                                      O 10 ######## V
PTBMYEQL K FKH CY LQZKTL TC."
                                      T 7 ### V
                                      U
       don't like "ao" – back up!
                                         #### V
```

```
a o e.a .a o
                      0.e
KDCY LQZKTLJKX CY MDBCYJQL: "TR
         .e a .ee.e .o
HYD FKXC, FQ MKX RLQQIQ HYDL
 a
              e .e .a
                                    K 10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                    L 10 ##
    o.e a .a. o e.a
                                    O 10 ######## V
PTBMYEQL K FKH CY LQZKTL TC."
                                    T 7 ### V
                                    U
                                    Y 6 #### V
```

```
a o re.a r.a o
                     o.e
KDCY LQZKTLJKX CY MDBCYJQL: "TR
         .e a freeze .o r
HYD FKXC, FQ MKX RLQQIQ HYDL
        . f re.e.a
 ar
                                   K 10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                   L 10 ##
    o.er a .a. o re.a r
                                   O 10 ######## V
PTBMYEQL K FKH CY LQZKTL TC."
                                   т 7 ### ∨
                                   U
```

Y 6 #### V

```
o re.a r.a o
                       \circ.e
KDCY LQZKTLJKX CY MDBCYJQL: "TR
                                   В 3
         .e a freeze .o r
HYD FKXC, FQ MKX RLQQIQ HYDL
         . f re .e .a
 ar
                                   K 10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                   L 10 ##
    o.er a .a. o re.a r
                                   O 10 ######## V
PTBMYEQL K FKH CY LQZKTL TC."
                                   т 7 ### ∨
                                   U
  frequent English letters: & t & & n i x s h
```

V

```
if
a no re.air.a no no.e
KDCY LQZKTLJKX CY MDBCYJQL: "TR
                                  В 3
.o .a n .e a freeze .o r
HYD FKXC, FQ MKX RLQQIQ HYDL
                                  н 3 .
     ni. f n re .e .a i
MKL DXCTW RDCDLQ JQMNKXTMB
                                  L 10 ##
                                  M 6 #
```

.i o.er a .a. no re.air in

PTBMYEQL K FKH CY LQZKTL TC."

```
K 10 ##### V
O 10 ######## V
T 7 ### V
U
Y 6 #### V
```

```
a to re.air.a to to.e if
KDCY LQZKTLJKX CY MDBCYJQL: "TR
                                 В 3
.o .a t .e a freeze .o r
HYD FKXC, FQ MKX RLQQIQ HYDL
                                 н 3 .
   ti. f t re .e .a i
MKL DXCTW RDCDLQ JQMNKXTMB
                                 L 10 ##
                                 M 6 #
```

.i o.er a .a. to re.air it

PTBMYEQL K FKH CY LQZKTL TC."

```
frequent cipher letters: & L K & D T M X X frequent English letters: & t & a n i t s h
```

K 10 ##### V O 10 ######## V T 7 ### V U Y 6 #### V

```
a to repair.a to to.e if
KDCY LQZKTLJKX CY MDBCYJQL: "TR
                                    В 3
.o .a t .e a freeze .o r
HYD FKXC, FQ MKX RLQQIQ HYDL
                                    н 3 .
   ti. f t re .e .a i
                                    K 10 ##### V
MKL DXCTW RDCDLQ JQMNKXTMB
                                    L 10 ##
                                    M 6 #
.i o.er a .a. to repair it
                                    O 10 ######## V
PTBMYEQL K FKH CY LQZKTL TC."
                                    T 7 ### V
                                    U
```

Y 6 #### V

```
frequent cipher letters: \cancel{Q} \cancel{X} \cancel{X} \cancel{C} D \cancel{X} M \cancel{X} X frequent English letters: \cancel{C} \cancel{X} \cancel{A} \cancel{A} n \cancel{X} \cancel{A} s h
```

auto repairman to customer: if KDCY LQZKTLJKX CY MDBCYJQL: "TR you wait we can freeze your HYD FKXC, FQ MKX RLQQIQ HYDL car until future mechanics

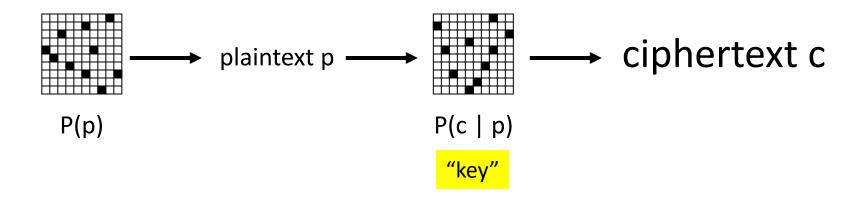
MKL DXCTW RDCDLQ JQMNKXTMB

discover a way to repair it

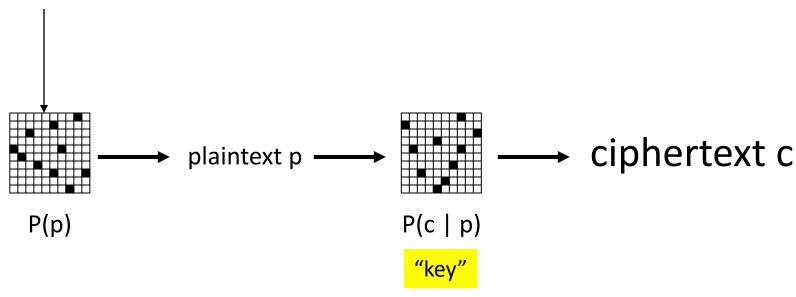
PTBMYEQL K FKH CY LQZKTL TC."

```
B 3
н 3.
K 10 ##### V
L 10 ##
M 6 #
Q 10 ####### V
T 7 ### V
U
Y 6 #### V
Z 2 .
```

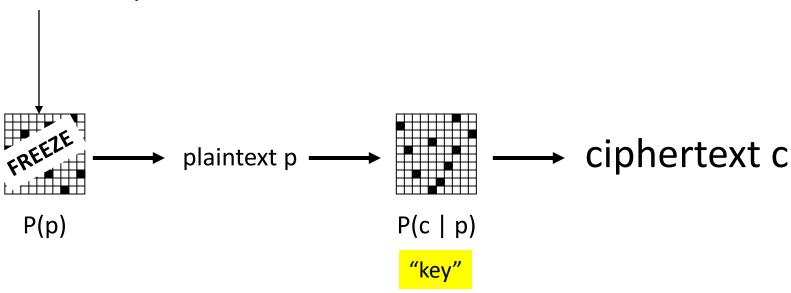
ciphertext c

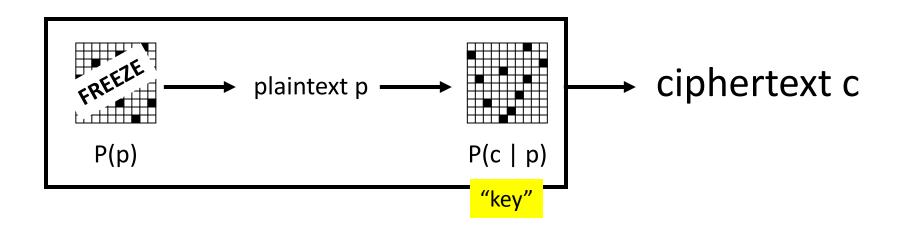


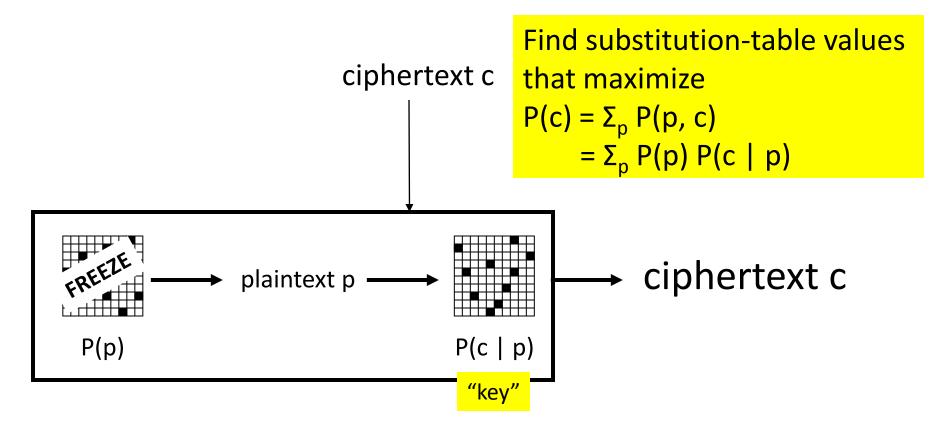
plaintext samples, unrelated to ciphertext

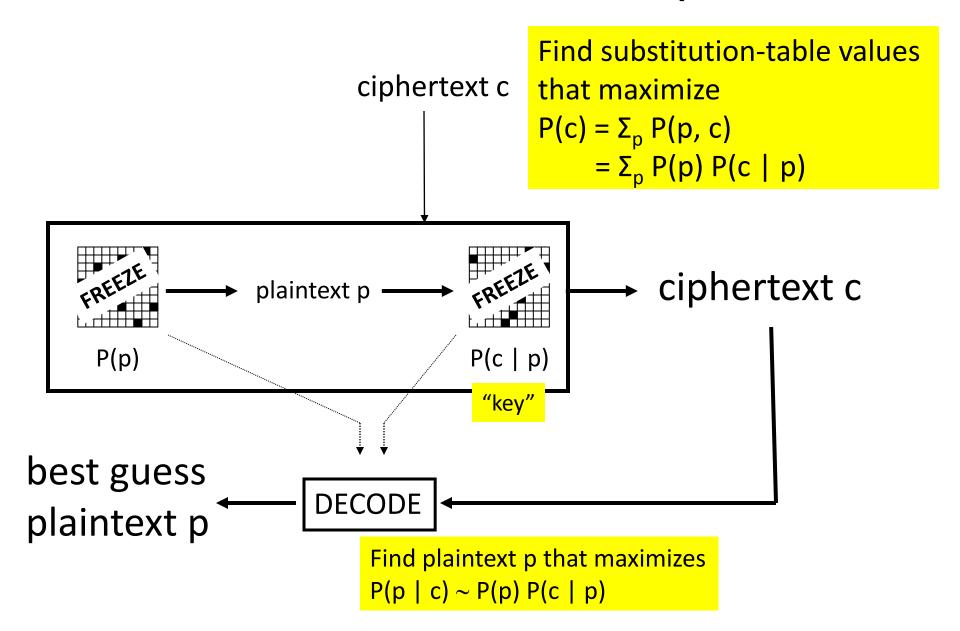


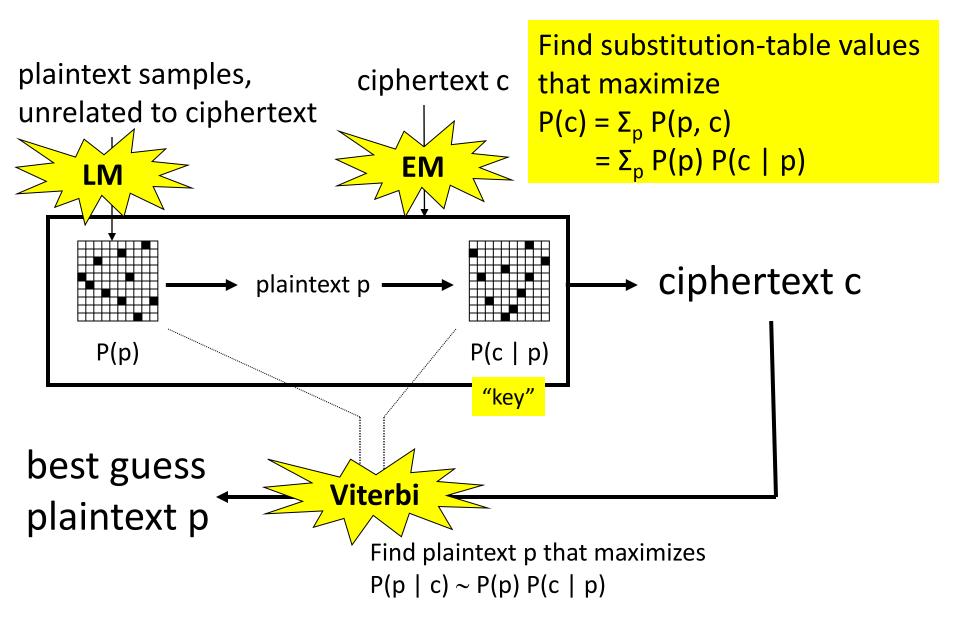
plaintext samples, unrelated to ciphertext



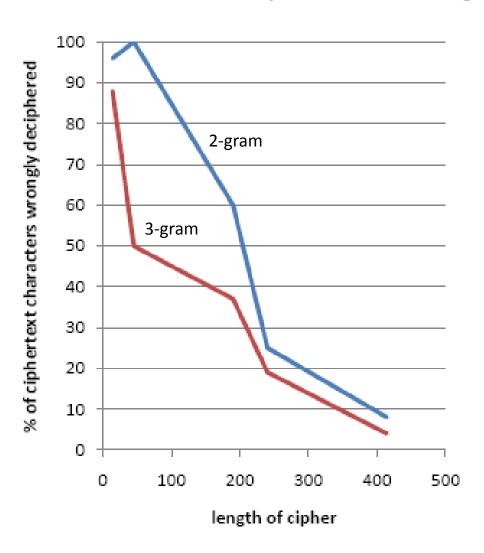


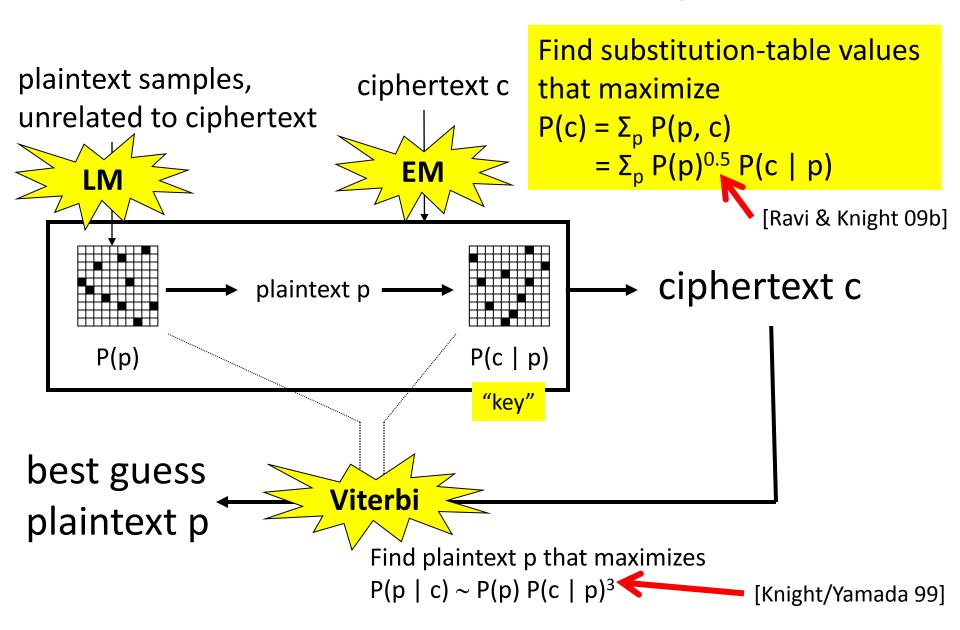




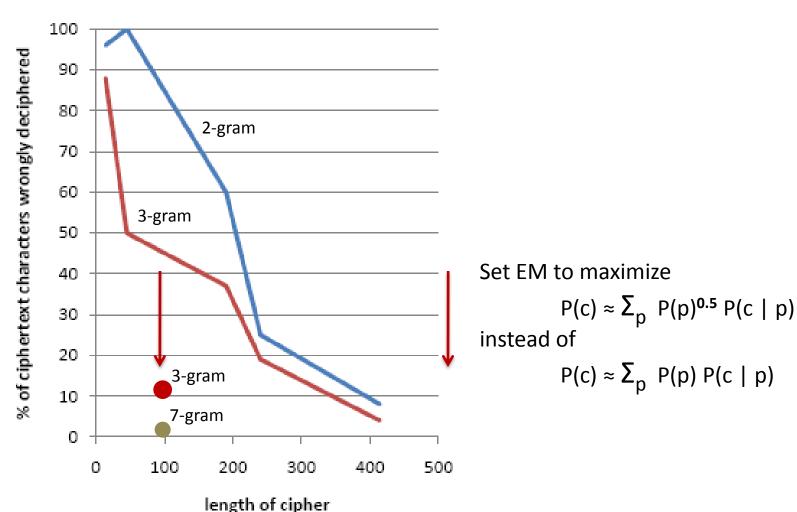


Decipherment Accuracy vs. Cipher Length





Reducing LM Weight During EM



Plan for This Talk

YOU

ARF

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography

ciphertext



ciphertext

primera parte del ingenioso hidalgo don ...

"When I look at these squiggles, I say to myself, this is really a sequence of Spanish phonemes, but it has been encoded in some strange symbols..."

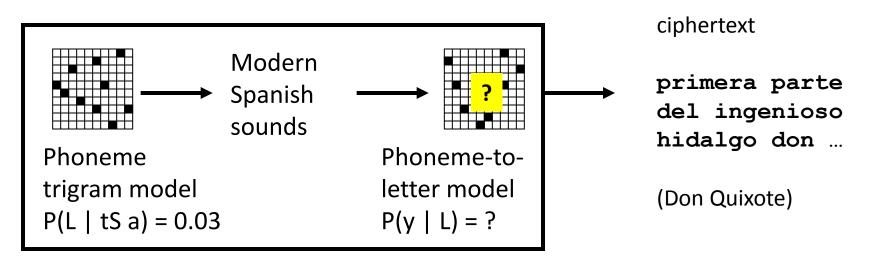
ciphertext

primera parte del ingenioso hidalgo don ...

(Don Quixote)



OUR HERO

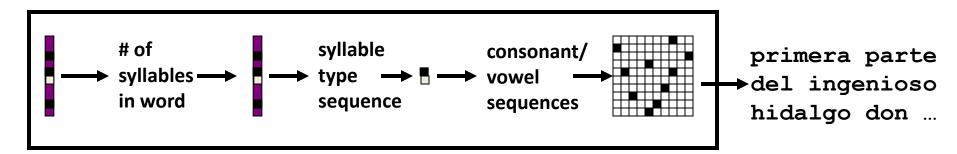


EM approach = 93% accurate phonetic decipherment

What if Spoken Language Behind Script is Unknown?

- Build a universal model P(p) of human phoneme sequence production
 - human might generally say: K AH N AH R IY
 - human won't generally say: R T R K L K
- Find a P(c | p) table
 - such that there is a decoding with a good universal P(p) score
- Phoneme & syllable inventory
 - if z, then s
 - all have CV syllables; if VCC, then also VC
- Syllable sonority structure
 - dram, lomp, ? rdam, ? lopm
- Physiological preference constraints
 - tomp, tont, ? tomk, ? tonp

Unknown Source Language



```
Input: primera parte del ingenioso ...
Output: NSV.NV.NV NVS.NV NVS VS.NV.SV.V.NV ...
```

S = sonorous consonant phoneme

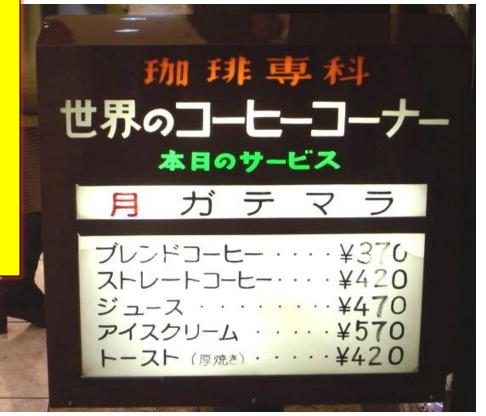
N = non-sonorous consonant phoneme

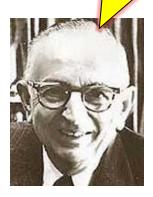
V = vowel phoneme

[Knight et al 06]

Phoneme Substitution Ciphers

When I look at street signs in Tokyo, I say: this is really written in English, but it has been coded in some strange symbols. I will now proceed to decode!





OUR HERO

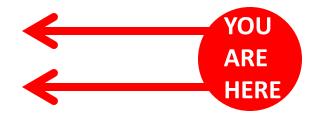
Parallel data:

Non-parallel data:

[Knight & Graehl 97] [Ravi & Knight 09a]

Plan for This Talk

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher



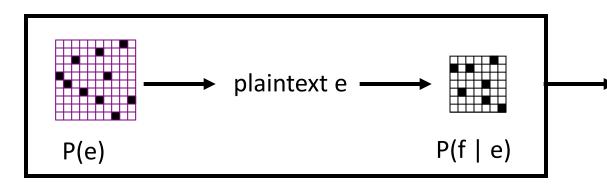
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography

Foreign Language as a Cipher

"When I look at this giant corpus of Arabic, I say to myself, this is really English, but it has been encoded in some strange symbols!!! Let's decode!!!"



OUR HERO



رفض رئيس السلطة الفلسطينية محمود عباس مجددا تصريحات وزير الخارجية الإسرائيلي سيلفان شالوم التي قال فيها إنه يتعين على إسرائيل إعادة النظر في انسحابها من غزة، المقرر أن يتم الصيف المقبل إذا فازت حركة وقال عباس في مؤتمر صحفي على هامش مشاركته في وقال عباس في مؤتمر صحفي على هامش مشاركته في القمة العربية-اللاتينية الأولى إنه يتعين على إسرائيل احترام خيار الشعب الفلسطيني حتى لو فازت حماس بالانتخابات، وأضاف "إذا نجحت حماس أو فتح سيكون هذا خيار الشعب الفلسطيني، وعلى الجميع قبول هذا حاب الخيار الشعب الفلسطيني، وعلى الجميع قبول هذا

من جانبه شجب رئيس الحكومة الفلسطينية أحمد قريع الطابع الأحادي الجانب للانسحاب الإسر اليلي من غزة، وأكد أن إسر ائيل تريد مغادرة هذه الأراضي لتعزيز ... سيطرتها على الضفة الغربية

وقال قريع في كلمة له خلال مؤتمر نظمته وزارة الأوقاف في رام الله "سينسحبون من غزة ولكننا لا نعرف ما هو شكل هذا الانسحاب وماذا سيتركون، وما هو مصير المعابر والحدود, وكل ذلك غامض لأنه قرار أحادي الجان

!|@!m !lywm !lth!ny& !l@!m !lm!Dy Sfr @!m th!ny& @!m 1992 @!m 1993 ywm !!!sbw@ !lm!Dy fy !ldqyq& !lsn& !lj!ry& !lsn& !lsh=hr !lm!Dy !lsh=hr !lj!ry snw!t sn& =hdh! !l@!m s!@& !l@Sr @!m 1991

Time Expressions

@!m 1990 w!lth!ny& fy!lywm mn !lsh=hr !lj!ry !lqrn !'y!m @!m!aN !|s!@& 17 shb!T 1994 thl!th snw!t dqyq& =hdh=h!lsn& ywmyn mn !|@!m !|m!Dy !lsn&!lmqbl& fy !lsn& kl ywm fy !|@!m !|m!Dy

!l@Swr =hdh! !lsh=hr fy ywm nys!n !sbw@ =hdh=h !!!'y!m qbl !'y!m fy!l@Sr mn !lsn& !lsnw!t b@d ywm !!!y!m 13 nys!n 1994 !lth!ny& @shr& thl!th& !y!m qbl !sbw@yn fy !lywm !lt!ly sh@b!n tmwz 3 dhw !lHj& 1414 fy shb!T !lm!Dy qbl ywmyn

!|@!m !lywm !lth!ny& !l@!m !lm!Dy Sfr @!m th!ny& @!m 1992 @!m 1993 ywm !!!sbw@ !lm!Dy fy !ldqyq& !lsn& !lj!ry& !lsn& !lsh=hr !lm!Dy !lsh=hr !lj!ry snw!t sn& =hdh! !l@!m s!@& !l@Sr @!m 1991

Time Expressions

@!m 1990 w!lth!ny& fy!lywm mn !lsh=hr !lj!ry !lqrn !'y!m @!m!aN is: wa 17 shb!T 1994 dqyq& =hdh=h!lsn& ywmyn mn !|@!m !|m!Dy !lsn&!lmqbl& fy !lsn& kl ywm fy !|@!m !|m!Dy

!l@Swr =hdh! !lsh=hr fy ywm nys!n !sbw@ =hdh=h !!!'y!m qbl !'y!m fy!l@Sr mn!lsn& !lsnw!t b@d ywm 13 nys!n 1994 11+hlnv& Ochia thl!th& !y!m qbl !sbw@yn fy !lywm !lt!ly sh@b!n tmwz 3 dhw !lHj& 1414 fy shb!T !lm!Dy qbl ywmyn

<n><n>* ??? 19<n><n>

9 Hzyr!n 1942

8 tshryn !!!wl 1990

7 k!nwn !!!wl 1993

6 !'y!r 1993

6!~Adh!r 1991

5 shb!T 1950

4 Hzyr!n 1989

30!~Adh!r 1944

29 !y!r 1945

29!~Adh!r 1993

28 k!nwn !!!'wl 1994

27 tmwz 1993

26 tmwz 1953

26 shb!T 1993

26 k!nwn !!!wl 1994

25 !ylwl 1926

24!~Adh!r 1993

22 !ylwl 1957

22 tshryn !!!wl 1948

22 tmwz 1952

21 !y!r 1994

21 k!nwn !!!wl 1988

21 Hzyr!n 1967

20 !'y!r 1990

20 tshryn !'wl 1983

20 tshryn !!!'wl 1921

1 !y!r 1994

17 Hzyr!n 1972

16 !ylwl 1919

16 Hzyr!n 1984

16!~Ab 1929

<n> Hzyr!n <n>

13	4 Hzyr!n 1967	2	fy 30 Hzyr!n 1995
12	fy 12 Hzyr!n 1993	2	fy 18 Hzyr!n 1994
7	5 Hzyr!n 1967	2	fy 14 Hzyr!n 1993
6	fy 30 Hzyr!n 1989	2	fy 14 Hzyr!n 1991
6	30 Hzyr!n 1989	2	fy 12 Hzyr!n 1990
4	fy 30 Hzyr!n 1994	2	7 Hzyr!n 1994
4	fy 30 Hzyr!n 1993	2	6 Hzyr!n 1941
3	fy 19 Hzyr!n 1967	2	26 Hzyr!n 1994
2	ywm 30 Hzyr!n 1989	2	21 Hzyr!n 1994
2	w 6 Hzyr!n 1994	2	1 Hzyr!n 1994
2	qbl 5 Hzyr!n 1967	2	19 Hzyr!n 1965
2	fy 9 Hzyr!n 1967	2	18 Hzyr!n 1994
2	fy 7 Hzyr!n 1981	2	18 Hzyr!n 1940
2	fy 6 Hzyr!n 1994	2	12 Hzyr!n 1993
2	fy 5 Hzyr!n 1967	2	11 Hzyr!n 1994

<n> Hzyr!n <n>

13	4 Hzyr!n 1967	2	fy 30 Hzyr!n 1995
12	fy 12 Hayrin 1993	2	fy 18 Hzyr!n 1994
7	5 Hzyr!n 1967	2	fy 14 Hzyr!n 1993
6	fy 30 Hzyr!n 1989	2	fy 14 Hzyr!n 1991
6	30 Hzyr!n 1989	2	fy 12 Hzyr!n 1990
4	fy 30 Hzyr!n 1994	2	7 Hzyr!n 1994
4	fy 30 Hzyr!n 1993	2	6 Hzyr!n 1941
3	fy 19 Hzyr!n 1967	2	26 Hzyr!n 1994
2	ywm 30 Hzyr!n 1989	2	21 Hzyr!n 1994
2	w 6 Hzyr!n 1994	2	1 Hzyr!n 1994
2	qbl 5 Hzyr!n 1967	2	19 Hzyr!n 1965
2	fy 9 Hzyr!n 1967	2	18 Hzyr!n 1994
2	fy 7 Hzyr!n 1981	2	18 Hzyr!n 1940
2	fy 6 Hzyr!n 1994	2	12 Hzyr!n 1993
2	fy 5 Hzyr!n 1967	2	11 Hzyr!n 1994

Time Expr

<n> Hzyr!n <n>

13	4 Hzyr!n 1967
12	fy 12 Hayr in 1993
7	5 Hzyr!n 1967
6	fy 30 Hzyr!n 1989
6	30 Hzyr!n 1989
4	fy 30 Hzyr!n 1994
4	fy 30 Hzyr!n 1993
3	fy 19 Hzyr!n 1967
2	ywm 30 Hzyr!n 1989
2	w 6 Hzyr!n 1994
2	qbl 5 Hzyr!n 1967
2	fy 9 Hzyr!n 1967
2	fy 7 Hzyr!n 1981
2	fy 6 Hzyr!n 1994
2	fy 5 Hzyr!n 1967

Search query	Documents
January 4, 1967	8040
February 4, 1967	9270
March 4, 1967	10700
April 4, 1967	21800
May 4, 1967	14000
June 4, 1967	39300
July 4, 1967	12600
August 4, 1967	7970
September 4, 1967	7390
October 4, 1967	8800
November 4, 1967	6560
December 4, 1967	9770

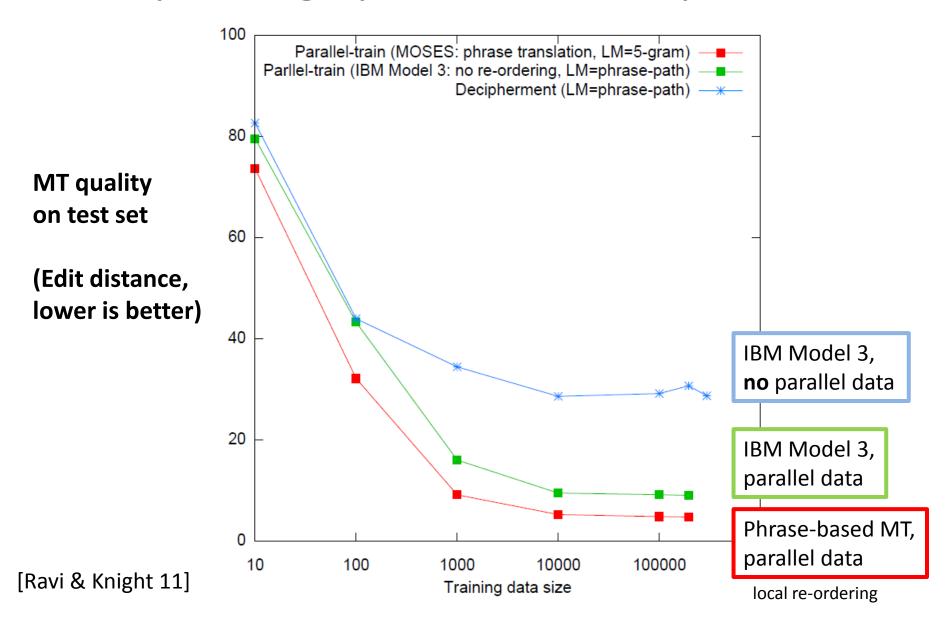
Hzyr!n

229	fy Hzyr!n !lm!Dy	16	n=h!y& Hzyr!n !lm!Dy
207	fy Hzyr!n	16	fy Hzyr!n 1990
75	fy Hzyr!n !lmqbl	15	sh=hr Hzyr!n
61	fy Hzyr!n 1993	15	fy sh=hr Hzyr!n !lm!Dy
31	fy Hzyr!n 1992	15	fy Hzyr!n 1994
27	!lr!b@ mn Hzyr!n	14	mn 17 Hzyr!n
27	fy Hzyr!n 1967	14	fy Hzyr!n 1996
19	fy 30 Hzyr!n !lm!Dy	14	fy 30 Hzyr!n
18	fy n=h!y& Hzyr!n !lm!Dy	13	fy sh=hr Hzyr!n
18	fy Hzyr!n 1991	13	fy 20 Hzyr!n !lm!Dy
17	mn Hzyr!n	13	4 Hzyr!n 1967
17	mndh Hzyr!n !lm!Dy	12	n=h!y& Hzyr!n
17	4 Hzyr!n	12	!lr!b@ mn Hzyr!n 1967

Hzyr!n

229	fy Hzyr!n !lm!Dy	16	n=h!y& Hzyr!n !lm!Dy
207	fy hzyr:	16	fy Hzyr!n 1990
75	fy Hzyr!n !lmqbl	15	sh=hr Hzyr!n
61	Ty Hzyrla 1003	15	fy sh=hr Hzyr!n !lm!Dy
31	fy Hzyr!n 1992	15	fy Hzyr!n 1994
27	!lr!b@ mn Hzyr!n	14	mn 17 Hzyr!n
27	fy Hzyr!n 1967	14	fy Hzyr!n 1996
19	fy 30 Hzyr!n !lm!Dy	14	fy 30 Hzyr!n
18	fy n=h!y& Hzyr!n !lm!Dy	13	fy sh=hr Hzyr!n
18	fy Hzyr!n 1991	13	fy 20 Hzyr!n !lm!Dy
17	mn Hzyr!n	13	4 Hzyr!n 1967
17	mndh Hzyr!n !lm!Dy	12	n=h!y& Hzyr!n
17	4 Hzyr!n	12	!lr!b@ mn Hzyr!n 1967

Deciphering Spanish Time Expressions



Plan for This Talk

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography



Copiale Cipher

zmzfzlilnx jcz nemlc j tiz rboyn k 3ôÿn nb+η nv πâs ก็เรามันกัก และเลือน เลือน e. h=nûr8cq3pagôjvn+bziôsenpm=romzplbnûd:nplo coffreting ายแต่กระงายงายเกาะการสารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานารายานา mmôrudyn: รัยกานเ+นิ่าช+ก่ายและรวฎพักลงนุโล๊ข้อมู พ+4* |z|m=mπxcîhəcirx|i=gzncoffAbηh+vzyz|êbgn+mzîjg3zıhâl h=[wzew benmosudhinmbhzr=+pmjj+hjuijolzn]njj gn+vuzyhzî3m)zrê+ariêcpic:prnqp mpaoolπû+v3polzju πυ hiselforajnremubstuvpcepreznneftcyeffrw zîjh Lbzya lûmhij pai 10 zozozozozo hotxû talnı loon i 10 xo 1+: 13 a=+gznzmon | xmmteÿnvzâ|bejimmâ | สุอในอทาใหนาชอง | น Ox30 Lazúlvπôd=ληβλυνχίμε vligrzy+barnπαπά3 morizolopmamzηâh nı funzlv to +b = ticumîrgznê h=โrittabogr:เกาอิกปะกุทธิ์งิ่มอังได้หรังองห์า:ใหอใฐภู:=แพ pjzzárga=gπνînzcηρzhċ:ûrghpmôluzuwps-ηπûrl=gz gποjuv innighasηουνπρ+2 alad+himofing isn dnûm:ênoś=lnjÿr)Yuemgr:dhiâsgqpmpic:g/vd3ΔΛολΔc:η

- 3âλomir milij+cn/kxrzkouc: ixmznôn Δοθετα : ua σÿεc: aipnnli=prôympb+piticsannnx-thicnub. Hpa∞+dxi/ic:ub.

υρίκ : 13 κ z li β b θέγ r êg c â hr c i r x ô b s = x μο μ li r πα κ m πν μ μ ωπ ê s | μ c em a f shi g z i π li b hi y 3 z n μ μ μ μ μ μ γ γ β β μ μ μ α κ μ α β shi g z i π μ λ hi y 3 z n μ μ μ μ μ μ μ γ γ β β μ μ α κ μ ρ ĉ i â ρ y δ μ ω δ ρ y z = n κ μ π μ ν | = 3 λ s b κ κ κ π y ê b m ô i | : μ ο η η π τ κ η m h g η μ μ z α κ 9 π ω + η λ κ Δ | : τ μ l ρ χ μ α μ ι η κ κ Δ | : τ μ l ρ χ μ α μ ι η κ κ Δ | : τ μ l ρ χ μ α μ ι η κ κ Δ | : τ μ l ρ χ μ α κ η κ κ Δ | : τ μ l ρ χ μ α κ μ ι η κ κ Δ | : τ μ l ρ χ μ α κ μ ι η κ κ Δ | : τ μ l ρ χ μ α κ μ ι ρ μ κ α κ μ α κ μ ι ρ μ κ α κ μ α κ μ ι ρ μ κ α κ μ α κ μ ι ρ μ κ μ κ α κ μ α κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι η μ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ κ μ ι ρ μ μ ι ρ μ κ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ μ ι ρ

Npê∞+b. Ln.
CΔρνοξέιγνοητάτ & Δηάÿχωλιηγως=3ghx|1

105 pages, 75000 letter tokens, no word spacing, no illustrations.

ก็เร่ามั่งกนะทุกใการสุดครั้งหังลังกลองกระเทพราระน์กราการขึ้งก e. h=nûr8co3pagojvn+bziossenpm=romzylbaûd:nplo coff ภาที่การอิง เการ์ เการ mmôrudon: sênpuitûjstnheug=rzgmasnulâygn w+q* |=|m=mπxcîħ3cirx|i=gzncoffsbηħ+vzy=|êbgn+mzîjg3=1ħâl h=[wze]w_ benmoudhinmbhzr=+pmpp+hpuilolznfnfj gn+vuzyhzîsm) rê+ariêcic: prnqp mpaolnû+vsyol ju πι lhis-lorajniemublituvpcepheznn:fcyeffaw zîja Lbzya jûmhi pairozozozozozotko trutholne bonzirox i +: 13 a=+gzn=mon | xmmfeÿnvzâ|bepimna| โปอโนอทาโพนิรอิ่ยาย Oxsof Lazûlνπôd=λησλιινχ jaf Lvhgrz+baranaπâз mor 200 อิอกลักรกลิโลกเบ็นกาย Lotato = houningsne h=lrit+âbogr:เกาอักนากและboaj ในหนางไมะในอำนาก pizzárga=gπνînzċηγzhċ:ûrghpmôluzuwpaηπûrl=gz gποjuv innxtanouvmp+1 alad+hmctmy îsn อกูนิm:enos=lnjyr) Yuemgr:อีกูเลิงอยุกโกกุล: สูโทฮงลกองลล:ก

Copiale Cipher

- sâλοmir millej+cijγκ×rzxōec: jxmzŋôn Δοθetcal:ua

ōÿêc:âijnnli=prôÿmpb+pthcsâŋnnxzthicnub.

Hpâ∞+ðxî/zc:ub.

wîŋr#+gnê=Acÿnuo kzopa drymm.

NHÊOO+b-In.

Caprocentrôngar & Anayxunchtbg=3ghxla

περικοι βορηγαμός παρικοι Paragraphs and section titles always begin with capitalized Roman letters.

Section headers

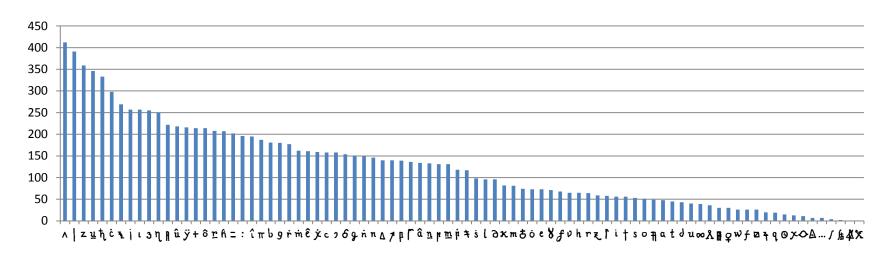
Lines ≈ equal length

Some scratch-outs, rare

Preview text fragments ("catchwords")

Non-enciphered inscriptions: Copiales 3 and Philipp 1866

Letter Frequencies



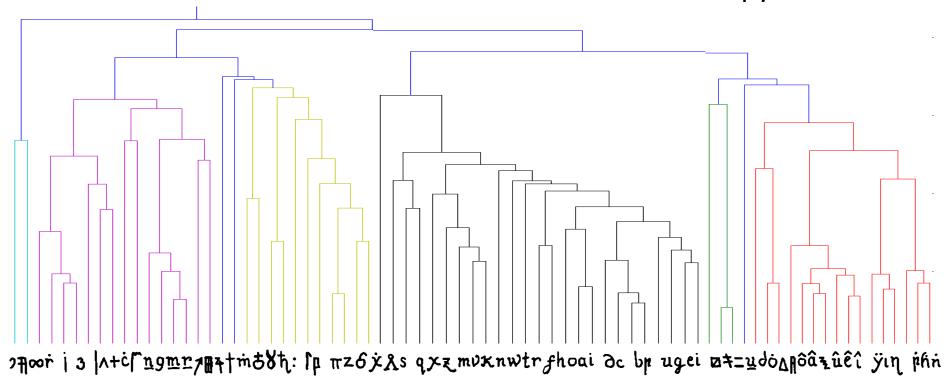
<u>digraphs</u> :		<u>trigraphs</u> :
o ħ	99	o t a 47
ċ:	66	ċ: <u>ч</u> 23
ħΛ	49	η 🤈 ħ 22
: ग्र	48	ÿ 🤈 ħ 18
Z A	44	hċ 17

tendencies:

â, ê, î, ô, û followed by 3 and j â, ê, î, ô, û preceded by z and π

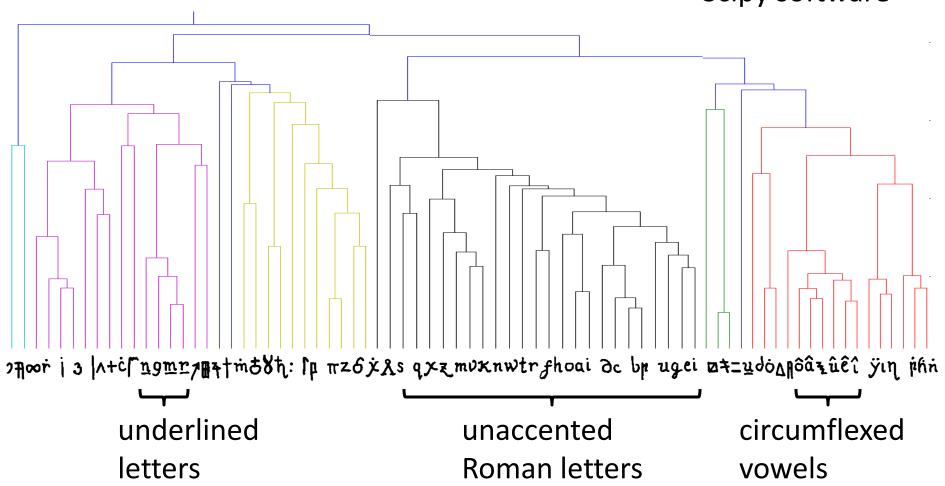
Clustering of Cipher Letters

letters grouped if they have similar contexts (L/R neighbors)
Scipy software



Clustering of Cipher Letters

letters grouped if they have similar contexts (L/R neighbors)
Scipy software



First Decipherment Approach

unaccented Roman letters that cluster:

abcdefghi Klmnopqrs tuvwxyz

most common letter = 12% least common = very small

Kmûr: kziôf | ÿoħêjħzιλnmâ3bAgz= ϳϻϲϫϻϼċλᾶͱ϶κλητητηλείπριδιτοηλα =gzwmÿêcarta+bznrixÿjîrzuf λz $\pi + \frac{1}{2} \frac{\partial \dot{r}}{\partial r} = \frac{1}{2} \frac{\hat{u}}{\partial s} + \frac{1}{2} \frac{\partial u}{\partial r} = \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{\partial$ Δ[:rînbι[um ÿjzvzâjx)pmπιzhncbogg zû+κτηηχεοghληηίηηλισthtpoyma +hhrzôgnbsn+:zrkpbnhocûng=nzk pzonzyofhirmzêÿng=rmgtanzyx πη μχ γ τ îgmu λ bg λι t b δ û [] η η 3 ô λ ez η ô larc 306 Aby tma

> kfnglknacbfzmk lbuvcghtrhbkgnkn fggnkbgbecb ...

Decipher against, 80 plaintext languages

First Decipherment Approach

unaccented Roman letters that cluster:

abcdefghi Klmnopqrs tuvwxyz

most common letter = 12% least common = very small

Kmûr: kziôf | ÿoħêjħzιλnmâ3bAgz= jzlzzpęchârgκληητηηλείηριωτοβλα =gzwmÿêcarta+bznrixÿjîrzuf λz $\pi + \frac{1}{2} \frac{\partial \dot{r}}{\partial r} = \frac{1}{2} \frac{\hat{u}}{\partial s} + \frac{1}{2} \frac{\partial u}{\partial r} = \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{\partial$ Δ[:rînbι[um ÿjzvzâjx)pmπιzhncbogg zû+κτηηχεοghληηίηηλισthtpoyma +hhrzôgnbsn+:zrkpbnhocûng=nzk pzonzhofhirmzêÿng=rmgtaonzhx πημχρέοπαλογλιτοδάρητοδλετηδ larc 306 Aby tma

> kfnglknacbfzmk lbuvcghtrhbkgnkn fggnkbgbecb ...



Second Decipherment Approach

Homophonic cipher, e.g.:

D = 刊 E = 文 *f* Δ * f î ¾ 3 F = μ

 $G = \ddot{y}$

etc.

Kmûr: rziôf | ÿoħêjħzinnmâ3b Δgz= jalzurgcaâtgκatyrthyazjnpîlatoya =gzwmÿêcarta+bznrixÿjîrzufaz $\pi + \frac{1}{2} \frac{\partial \dot{r}}{\partial r} = \frac{1}{2} \frac{\hat{u}}{\partial s} + \frac{1}{2} \frac{1}{2}$ D[:rînbilum ÿjzvzâjxppmmizhncbogg zû+κτηηχεσομληήηηλισtn+royma +hhrzôznbin+:zrkfp6phocûng=nzk pzonzysfhirmzêÿng=rmgtasnzyk πη μχ Ϋ τ ί 9 π 12 λ ο β λι † ο δ û [] η η 3 ο λ ε Ζ η ο |ûrc| 306161 tma

Homophonic Cipher

Result of computer attack on Copiale, using 80 possible plaintext languages?



But, slight numerical preference for German

Cipher Characteristics

digrap	ohs:	trigraphs:	tendencies:
o ħ	99	o ħ x 47	ââ^âfallowed by a and i
ċ:	66	ċ: <u>и</u> 23	â, ê, î, ô, û followed by 3 and j
ኪ ^	49	η 1 ή 22	â, ê, î, ô, û preceded by z and π
: দ্র	48	ÿ n ħ 18	
z p	44	hċ 17	? ?

Make full digraph table for cipher and for German

should appear

adjacent in German text

Key Observation #1

In Copiale, ? almost always followed by ħ.
In German, C almost always followed by H.
(German CH is like English QU)

So guess: $\mathfrak{I} = C$, $\mathfrak{h} = H$

One Thing Leads to Another

$$2\hbar = CH \rightarrow 2\hbar \Lambda = CHT \rightarrow \Lambda = T$$
?

Each step is guesswork.

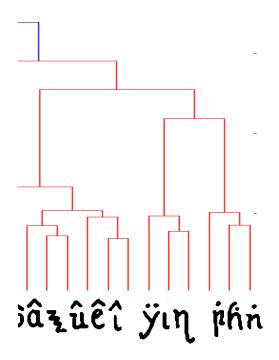
Must be willing to retract.

Weird task, not knowing German.

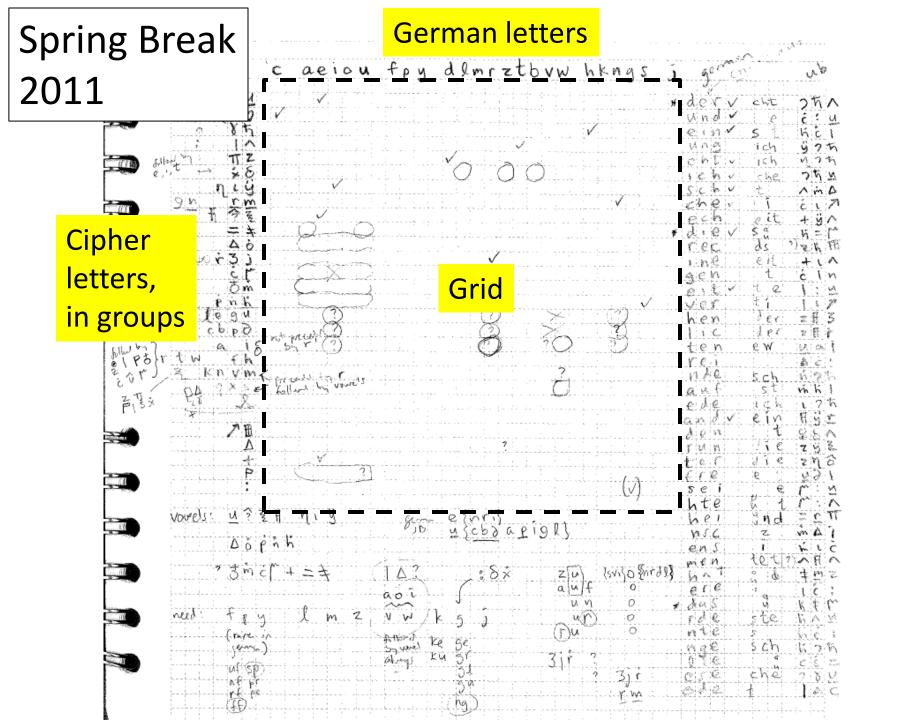
No longer care what the book says.

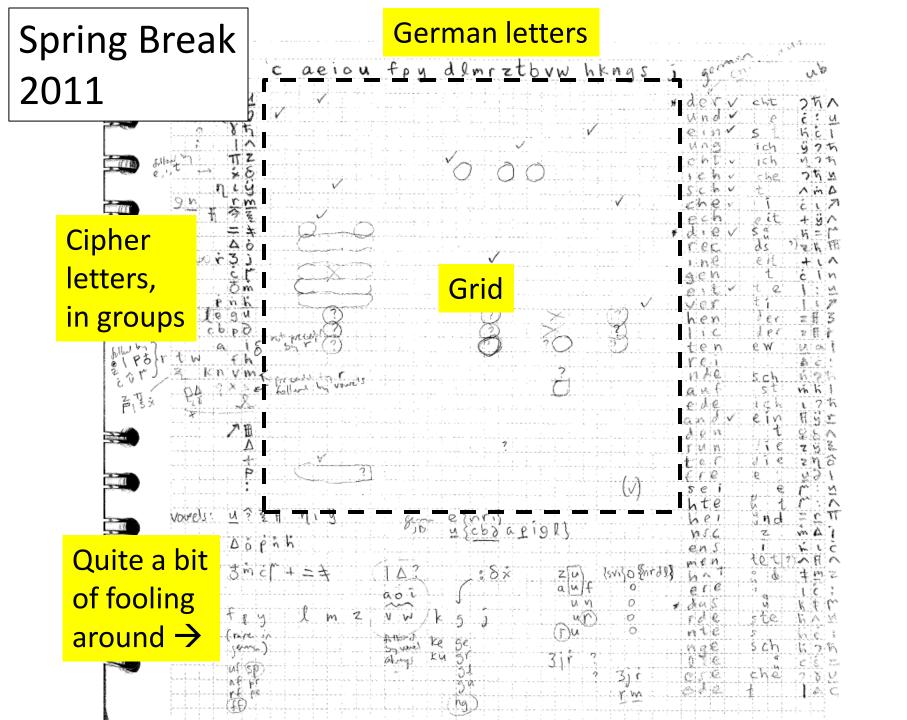
Cluster diagram crucial:

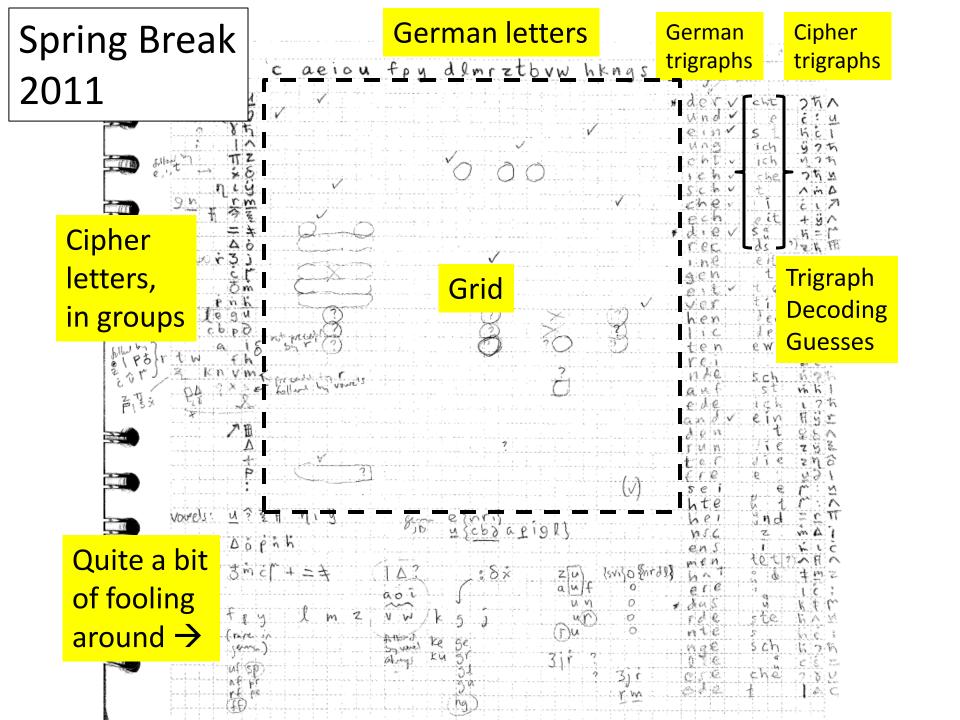
$$\ddot{y} = I \rightarrow \iota = I$$
, $\eta = I$



Spring Break 2011 Dopah







Key Observation #2

unaccented Roman letters that cluster:

```
abcdefghi
Klmnopqrs
tuvwxyz
```

Kmûr: kziôf | ÿoħêjħzιλnmâ3bAgz= ϳϻϲͷϻϼċλᾶϔσκληΫτηλείπριδιάδηλα =gzwmÿêcarta+bznrixÿjîrzuf λz $\pi + \frac{1}{2} \partial \dot{r} = \frac{1}{2} \hat{u} \wedge \dot{s} + \frac{1}{2} \hat{u} \wedge \dot{s} + \frac{1}{2} \frac{1}{2} \hat{u} \wedge \dot{s} +$ Δ[:rîλbι[umÿjzvzâjx)pmπιzhλcbogg zû+kznn xê39h n thịt nh î3th trôymâ +hhrzôznbin+:zrkpontoing=nzk pzonzpoftienzêÿng=engtanznx πη μχ ÿτ îgmu λbg λι tb δû [] η η 3ô λez η ô lurc 306 Abn tma

Actually, those are space bars

Copiale Decipherment

lit:mzA|bl vxz|însxp+z|wn

πô|νηΔρέ3ċα=ρλûδΦur Φz

δηη τι+ô|ημλη ίη ċ f.

cû|[ê3tμρ+9ηλ:χ

δχῦη êη+τμ+mλί3:ÿρλιδό|qzιίχα|êċ:uð.

βῦμβομχιλιλ=ċz.

πημά +Δο ÿμχεος mɨξημη + ίf.

κών τι τι δ β | Υρηθί η τι καπά ο δ Δ ρ Ζ τί γι Ζ μρο δα κό το κλη η τη η λ τί η ρί | Δ τό η κα το ρε ωπ με ε Δ τό Δ το τι χμί τε τω β λ τ π τί γ δί τε τι δι β το με τι λ μι λ δι με τι λ κι με με τι λ με τ

nîrfcizeophôrapz6ûtzáxΦgs=amêjzuli

φ ś m û ∞ Λο η | οπεθυ ο ο τι τι σο τι τι σο τ

lπο3 fohgz ÿπβλικωλώΔελβλοετάς.

gesetz buchs der hocherleuchte � e Ø

geheimer theil. erster abschnitt geheimer unterricht vor die gesellen. erster titul.

ceremonien der aufnahme. wenn die sicherheit der ∆ durch den ältern

thürheter besorget und die \(\Delta\) vom dirigirenden \(\mathbb{X}\) durch aufsetzung seines huths geöffnet ist wird der candidat von dem jüngern thürhüter aus einem andern zimmer abgeholet und bey der hand ein und vor des dirigirenden \(\mathbb{X}\) tisch geführet dieser frägt ihn:

erstlich ob er begehre 🔷 zu werden

zweytens denen verordnungen der **②** sich unterwerffen und ohne wiederspenstigkeit die lehrzeit ausstehen wolle.

drittens die A der O gu verschweigen und dazu auf das verbindlichste sich anheischig zu machen gesinnet sey.

der candidat antwortet ja.

Copiale Decipherment

lit:mzA|bl vxz|însxp*z|wn

πορηληεικά=ηλάδ**Φ**μη**Θ**ξ

δητι+δίηνητηίης f. cûjlêstiptgηλ:κ

mmra+Agyuxzôzmi+[nhh+îf.

κώντιμοιο β | Υρηθίη τιλη πά ο δο Δροσίρ | ευμφό λά το κλη η τη η λη τη η είρο με το κατά το κλη η τη η λη τη η είρο με το κατά τι κατά το κα

nîrîcizeophôr δρεδû ti sâx Ο gis z dmêjz uli

φέπῶωλοη|οπεθυσοξτά|29+μχως πῶσχ Φη|ηγυ=η
Λετπος Γ: μα=μειδημηοπη αεο||διμιοδούλονειεφεαή
τέξη Λ
εμ=|[αημυπαέ: το.

hzjηλ:ôglezηᾶz Αππᾶο Φρέττδιο τ πά ÿ δυμί=ηπ zpis=nht [rzpint ipigπc ÿo h [ôb| νκή g h i ÿ ti δcis=b+ή νω δ χοι n:ûλν ιωn.

lmô3,fohgzÿπβλικωλώΔτλβλοεξάτ.

First lawbook

of the 🔷 e 🗿

Secret part.

First section

Secret teachings for apprentices.

First title.

Initiation rite.

If the safety of the \triangle is guaranteed, and the \triangle is opened by the chief \mathbb{R} , by putting on his hat, the candidate is fetched from another room by the younger doorman and by the hand is led in and to the table of the chief \mathbb{R} , who asks him:

First, if he desires to become **②**.

Secondly, if he submits to the rules of the **②** and without rebelliousness suffer through the time of apprenticeship.

Thirdly, be silent about the A of the o and furthermore be willing to offer himself to volunteer in the most committed way.

The candidate answers yes.

Copiale Decipherment

lit:mz¶bl vx̃₹|î∧š*kp*≠|wn Everything documented at http://stp.lingfil.uu.se/~bea/copiale Google: "copiale"

πδίνηδηθες έα τη λάβου μο Ο τ

mηrâ+Δgÿuxzôgmn+[nht+îf.

χώντικτιο β | Υο ηθίη τιλη πά ο δο Δο τ τίν με με καθέσκα η τη ηλ τίν με με καθένες δε δο κατά το κα

nîricizeophôr οριδιή 3 ακ Ogs= Omêjzuli

şɨmû∞λôn|oπêguððzra|zgtrkugmûxæn|ηzb=n λêrmôs[:ua=rzlatrβðmnûzô||dír[ιδδοÿλνzιêgċût rɨênλ cμ=|[âtubmaċ:zð.

hzjηλ:ôglezηᾶz μπα3Φρέ+rðî3†mâÿ6uli=nπ zpś=nh+[rzphtð*ipιgπċÿ>ħ[ôblizkngħ*ÿ†ι6cś=b+nzuð χοιπ:ûλν]îon.

lmô3 fohgz ÿπβλικπλώΔτλβλοεγάτ.

First lawbook of the **O** e **O**

Secret part.

First section

Secret teachings for apprentices.

First title.

Initiation rite.

If the safety of the \triangle is guaranteed, and the \triangle is opened by the chief \mathbb{R} , by putting on his hat, the candidate is fetched from another room by the younger doorman and by the hand is led in and to the table of the chief \mathbb{R} , who asks him:

First, if he desires to become **②**.

Secondly, if he submits to the rules of the **②** and without rebelliousness suffer through the time of apprenticeship.

Thirdly, be silent about the A of the o and furthermore be willing to offer himself to volunteer in the most committed way.

The candidate answers yes.

Voynich Manuscript



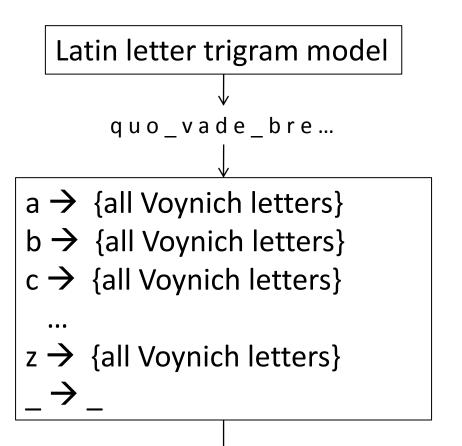
- Medieval illustrated manuscript
- 235 pages, 6 sections, 38k word tokens, 35 letter types
- Undeciphered

Voynich Manuscript

They follow dellow deller police exteres quites plans offers series and research and series and are series are series and series are series are series and series are series are

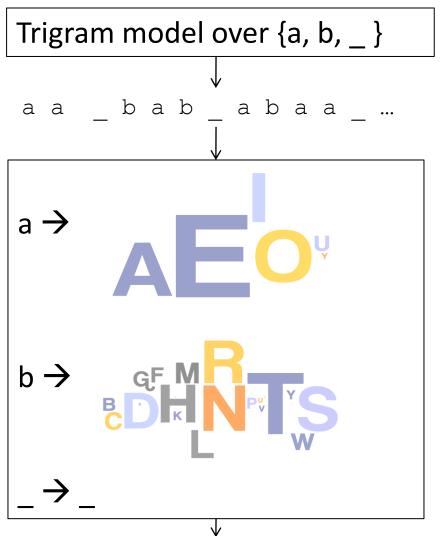
BSC8AE OPCC9 40E FCC89 40FCC9 40P9 SCBS9 40BSC9 EFAM OPAE29 2ZC9 40FC89 40FAM Z89 40FCC9 SC89 40FCC9 40FCC9 ESC89 EOP9 8ZC9 40PCCC9 8ARSC89 40FC9 40P9

Voynich Letter Substitution



Input	Decipherment
VAS92 9FAE AR APAM ZOE ZOR9	quiss squm is onum pom
QOR92 9 FOR	quss hates s
ZOE89	qum hatis





Sample tagging with learned model:

```
      a
      b
      -
      b
      a
      -
      b
      a
      b
      b
      -

      i
      n
      -
      t
      h
      e
      -
      t
      o
      w
      n
      -

      b
      b
      a
      b
      a
      -
      a
      -
      ...
      ...

      w
      h
      e
      r
      e
      i
      ...
      ...
```

in_the_town_where_i_was...

Trigram model over {a, b, _ }

aa _bab_abaa_...

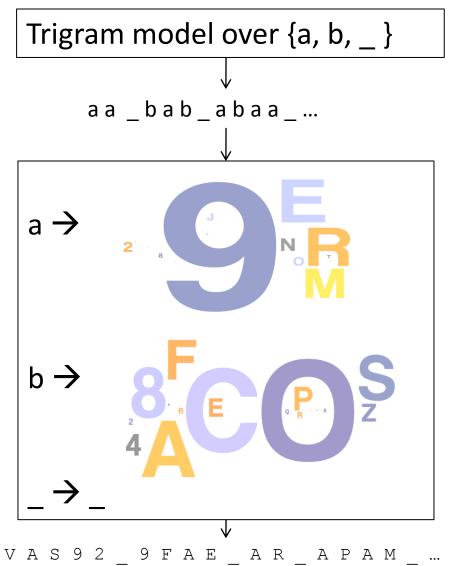
a → {all Voynich letters}

b → {all Voynich letters}

_ → _

Sample tagging with learned model:

A P A M _ Z O E _ Z O R 9 _ ...



Sample tagging with learned model:

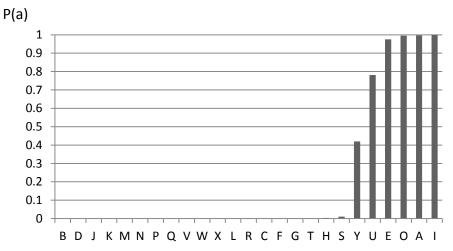
```
b b b a _ a _ a b b a _ b a _ b a _ 
V A S 9 2 _ 9 F A E _ A R _ 
b b b a _ b b a _ b b a _ b b a _ ...
A P A M _ Z O E _ Z O R 9 _ ...
```

P(letter | tag)

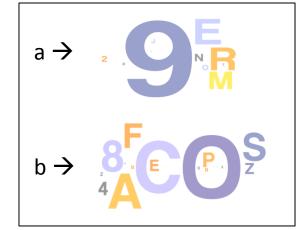
English

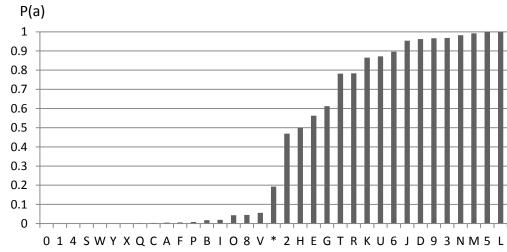


P(tag | letter)



Voynich

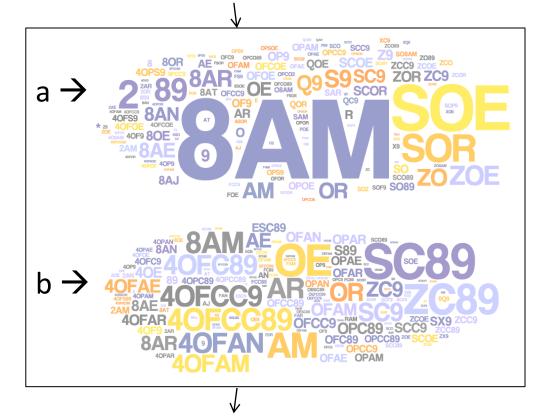




Word Clustering

Bigram model over {a, b}

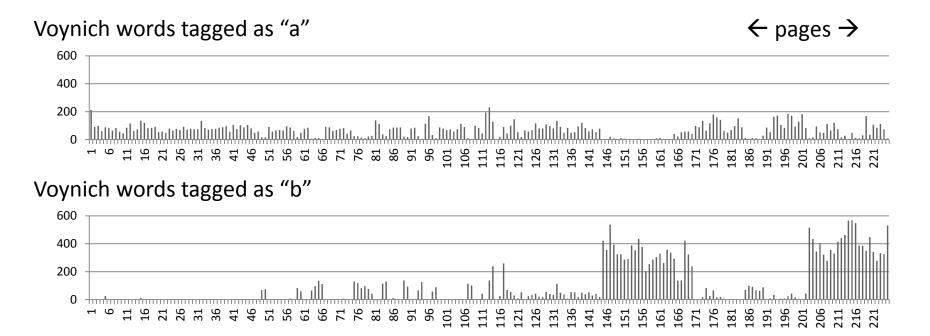
aabababaa...



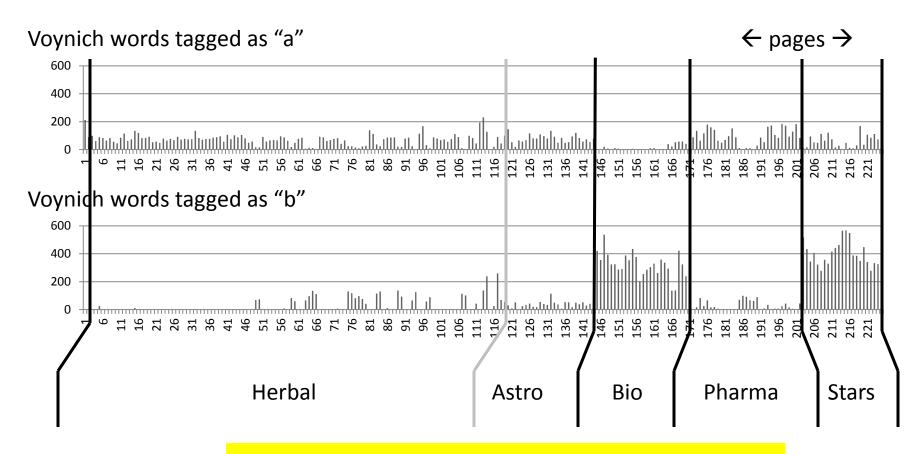


VAS92 9FAE AR APAM ZOE ZOR9 QRC2 9 ...

Word Clustering

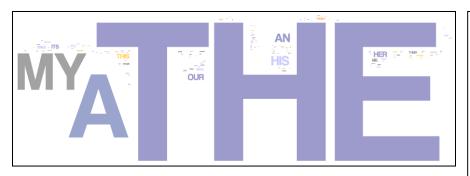


Word Clustering



Voynich sections, per drawings observed. Captain Currier's "two languages" (1976).

10-Class Word Clustering: English

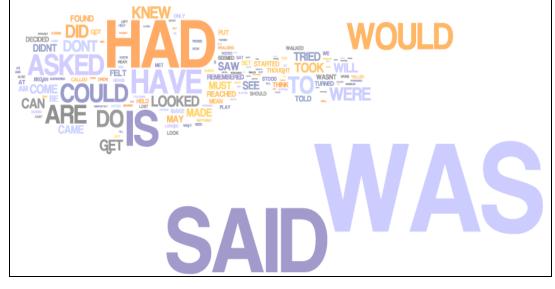


etc

etc

etc



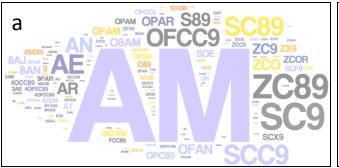




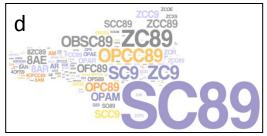
etc

etc

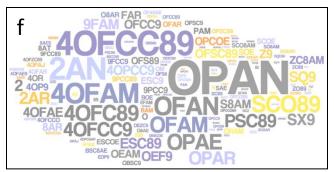
etc











10 Classes: Voynich-B (Bio+Stars)











Other Unsolved Ciphers

Voynich Manuscript (1400) Reddy & Knight 11

They wall by gellow des gotters exists polling gellong gellong gellong stress solo

Zodiac 408 Serial Killer (1967)

Lost Language Decipherment



Snyder, Barzilay, Knight 10

FBI cipher (1999)

ALPHTE GLSE-SE ERTE VLSE MTSE-CTSE-WSE-FRTSE PURTRSE ON PRSEMED NOSE NWLDXCRCMSP NEWLDSTS NEWL

Kryptos (1990)

OBKR

UOXOGHULBSOLIFBBWFLRVQQPRNGKSSO TWTQSJQSSEKZZWATJKLUDIAWINFBNYP VTTMZFPKWGDKZXTJCDIGKUHUAUEKCAR Unsupervised Training for NLP

Machine Translation ...

Plan for This Talk

- Break a series of codes
 - Simple letter substitution
 - Phonetic substitution
 - archaeology
 - transliteration
 - Word substitution
 - Foreign language as cipher
- Bonus
 - Two historical ciphers
 - Final thought on translation and cryptography



Future Prospects for Translation

		Cryptography	Translation	
Manual		Manual encoding	Human translation	
Mechanical		^{1920s} Mechanical encoding; intuition-based decryption		
Mathematical	$0 \xrightarrow{1-p} 0$ $1 \xrightarrow{1-p} 1$	1950s Computer decryption, based on information theory		
Higher math, deeper understanding	-RSA	Public-key systems, based on number theory		

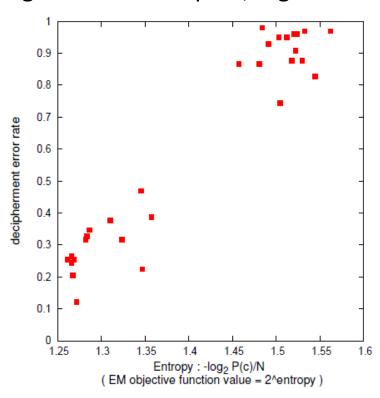
Future Prospects for Translation

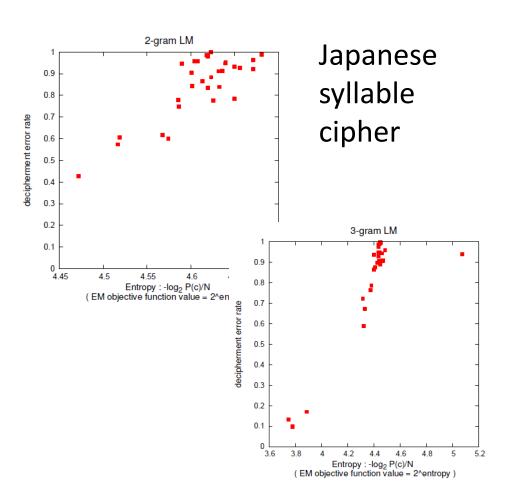
		Cryptography	Translation	
Manual		Manual encoding	Human translation	
Mechanical	ill Ci	1920s Mechanical encoding;	1960s	
	L. C.	intuition-based decryption	Rule-based MT	
Mathematical	$0 \xrightarrow{1-p} 0$	^{1950s} Computer decryption,	1990s	
	$1 \xrightarrow{p} 1$	based on information theory	Statistical MT	
Higher math,	-RSA	^{1980s} Public-key systems,	2020s	
deeper understanding		based on number theory	??? ??? ???	

thanks

Random Restarts are Critical

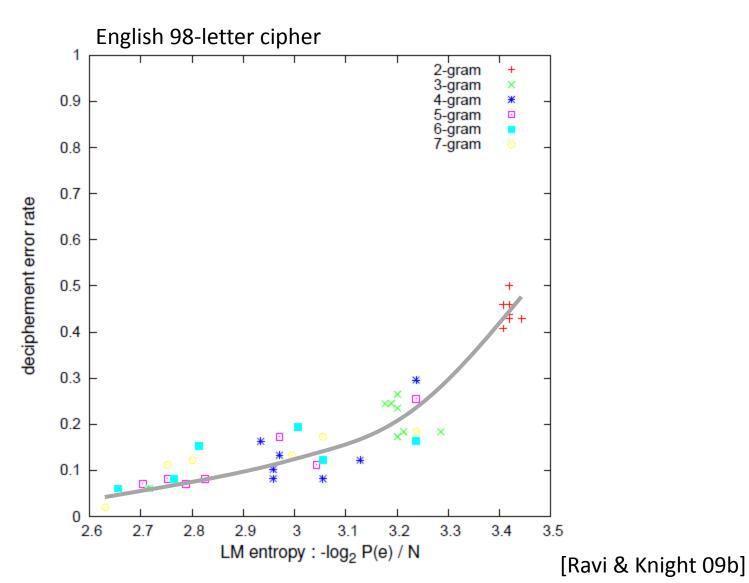
English 98-letter cipher, 3-gram LM





even people do restarts!

Good Language Models are Critical



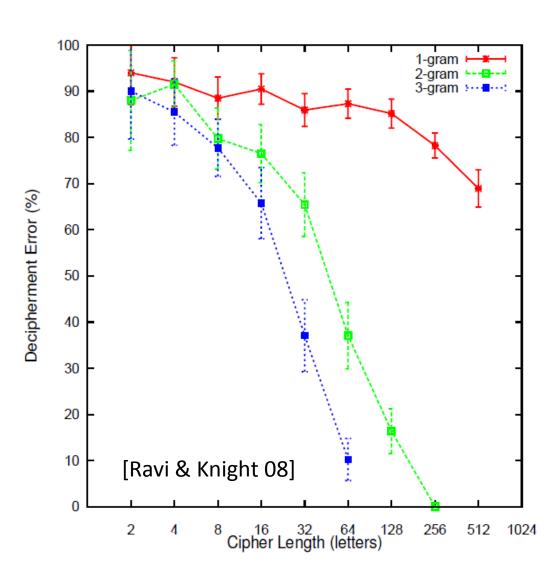
Deterministic Substitution Constraint

Using ILP instead of EM

- * Search only over deterministic keys.
- * Exact, no restarts.

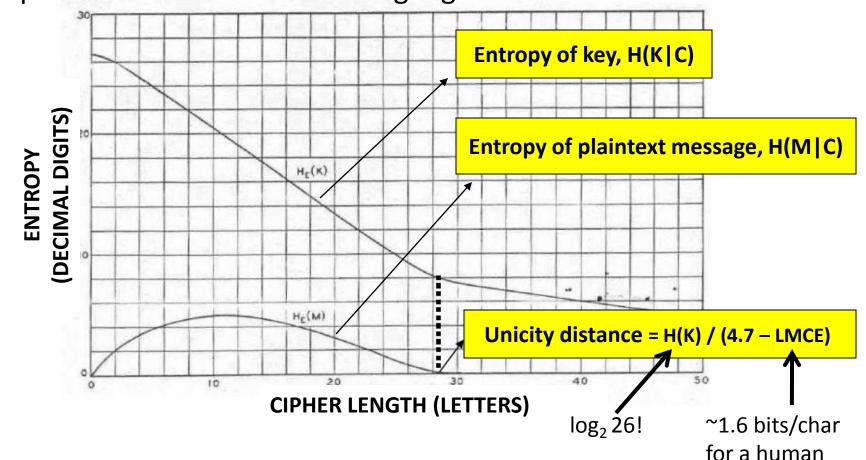
		4
Cipher	EM	ILP
Length	error	error
52	85 %	21 %
98	45 %	12 %
414	10 %	0.5 %

Using 2-gram letter-based LM

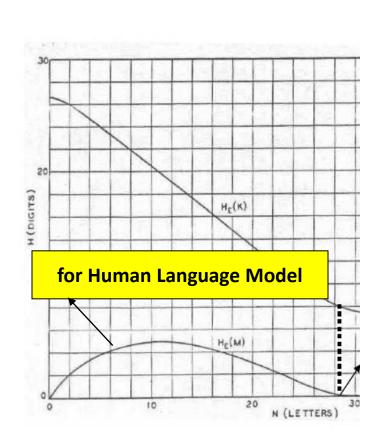


[Shannon 46, 49] "Communication Theory of Secrecy Systems"

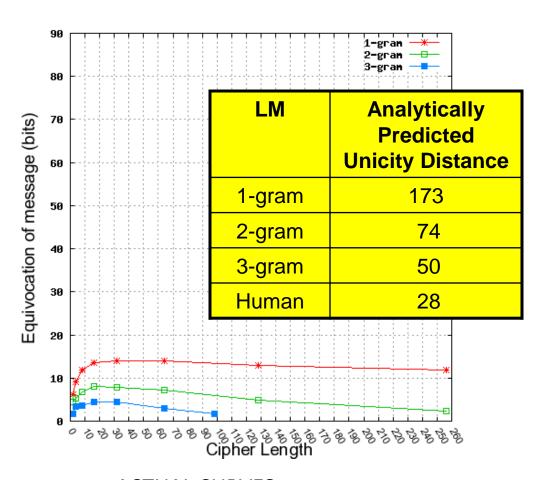
- Shannon analytically predicted uncertainty about key and message
- Graphed it for a human-level language model



Verifying Shannon's Prediction of Plaintext Message Uncertainty



ANALYTIC CURVES (Shannon's)



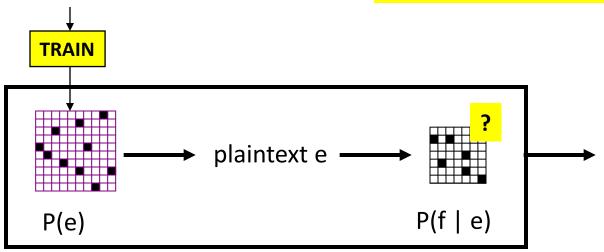
ACTUAL CURVES (ours)

[Ravi & Knight 08]

Foreign Language as a Cipher

BAGHDAD, Iraq (CNN) -- Six bombings killed at least 54 Iraqis and wounded 96 others Wednesday, including 20 civilians who died as they lined up to join the Iraqi army in Hawija when a suicide bomber detonated explosives hidden under his clothing, Iraqi officials said. That attack in the town about 130 miles (209 kilometers) north of Baghdad also wounded 30 Iraqis, said Iraqi army Lt. Col. Khalil al-Zawbai. A car bombing in Saddam Hussein's ancestral homeland of Tikrit also killed 30 Iraqis and wounded another 40, Iraqi officials said. The Tikrit explosion...

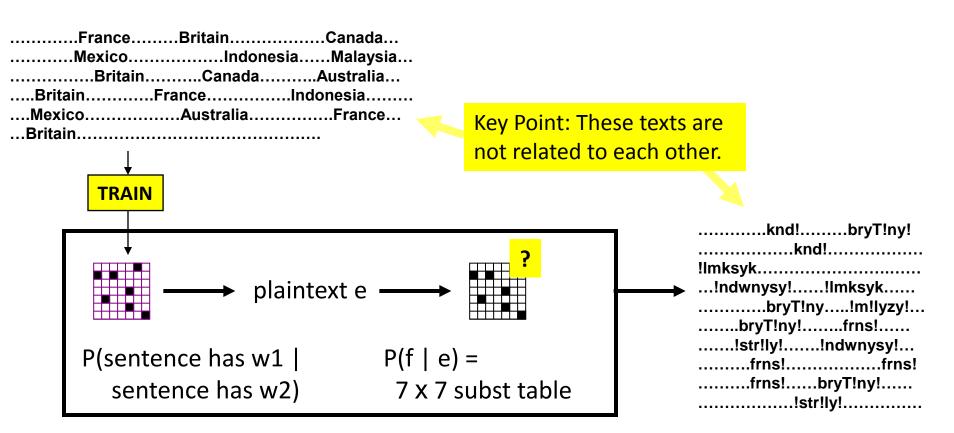
Key Point: These texts are not related to each other.



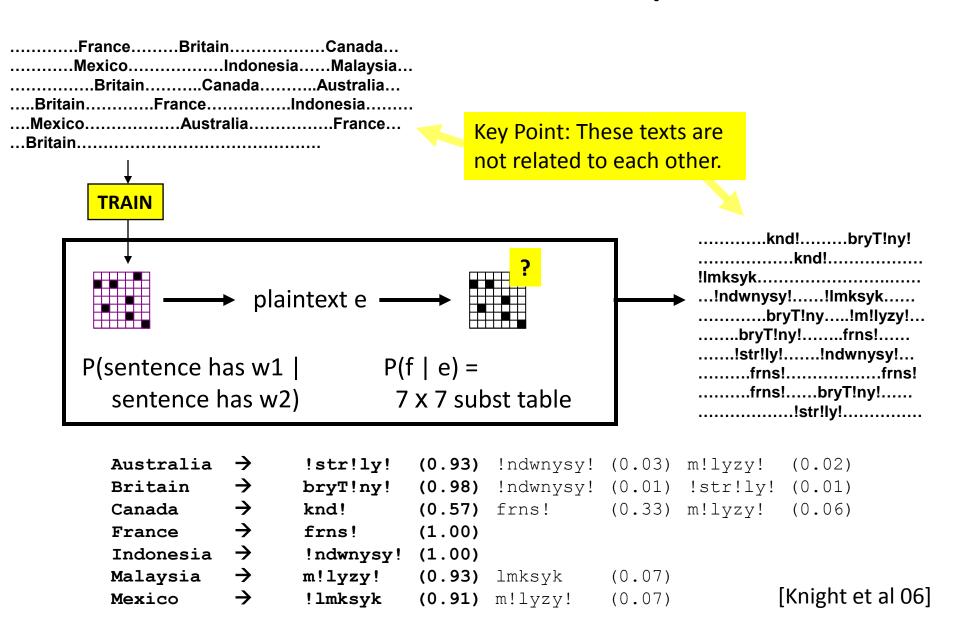
رفض رئيس السلطة الفلسطينية محمود عباس مجددا تصريحات وزير الخارجية الإسرائيلي سيلفان شالوم التي قال فيها إنه يتعين على إسرائيل إعادة النظر في انسحابها من غزة، المقرر أن يتم الصيف المقبل إذا فازت حركة . المقاومة الإسلامية حماس في الانتخابات التشريعية وقال عباس في مؤتمر صحفي على هامش مشاركته في القمة العربية اللاتينية الأولى إنه يتعين على إسرائيل احترام خيار الشعب الفلسطيني حتى لو فازت حماس بالانتخابات، وأضاف "إذا نجحت حماس أو فتح سيكون هذا خيار الشعب الفلسطيني، وعلى الجميع قبول هذا حبار الشعب الفلسطيني، وعلى الجميع قبول هذا

وقال قريع في كلمة له خلال مؤتمر نظمته وزارة الأوقاف في رام الله "سينسحبون من غزة ولكننا لا نعرف ما هو شكل هذا الانسحاب وماذا سيتركون، وما هو مصير المعابر والحدود, وكل ذلك غامض لأنه قرار أحادي الجان

Word Substitution Cipher

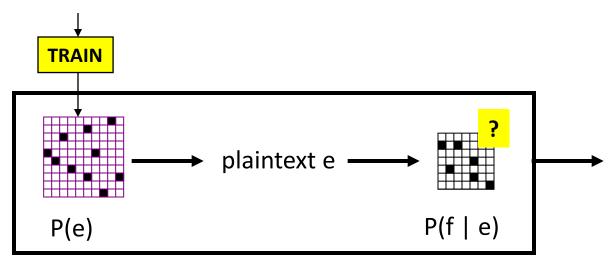


Word Substitution Cipher



Foreign Language as a Cipher

BAGHDAD, Iraq (CNN) -- Six bombings killed at least 54 Iraqis and wounded 96 others Wednesday, including 20 civilians who died as they lined up to join the Iraqi army in Hawija when a suicide bomber detonated explosives hidden under his clothing, Iraqi officials said. That attack in the town about 130 miles (209 kilometers) north of Baghdad also wounded 30 Iraqis, said Iraqi army Lt. Col. Khalil al-Zawbai. A car bombing in Saddam Hussein's ancestral homeland of Tikrit also killed 30 Iraqis and wounded another 40, Iraqi officials said. The Tikrit explosion...



رفض رئيس السلطة الفلسطينية محمود عباس مجددا تصريحات وزير الخارجية الإسرائيلي سيلفان شالوم التي قال فيها إنه يتعين على إسرائيل إعادة النظر في انسحابها من غزة، المقرر أن يتم الصيف المقبل إذا فازت حركة . المقاومة الإسلامية حماس في الانتخابات التشريعية وقال عباس في مؤتمر صحفي على هامش مشاركته في القمة العربية اللاتينية الأولى إنه يتعين على إسرائيل احترام خيار الشعب الفلسطيني حتى لو فازت حماس بالانتخابات، وأضاف "إذا نجحت حماس أو فتح سيكون هذا خيار الشعب الفلسطيني، وعلى الجميع قبول هذا حيار الشعب الفلسطيني، وعلى الجميع قبول هذا خيار الشعب الفلسطيني، وعلى الجميع قبول هذا

من جانبه شجب رئيس الحكومة الفلسطينية أحمد قريع الطابع الأحادي الجانب للانسحاب الإسر اليلي من غزة، وأكد أن إسرائيل تريد مغادرة هذه الأراضي لتعزيز سيطرتها على الضفة الغربية .

وقال قريع في كلمة له خلال مؤتمر نظمته وزارة الأوقاف في رام الله "سينسحبون من غزة ولكتنا لا نعرف ما هو شكل هذا الانسحاب وماذا سيتركون، وما هو مصير المعابر والحدود, وكل ذلك غامض لأنه قرار أحادي الجان

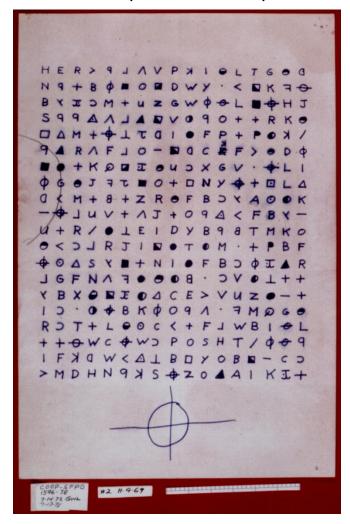
Zodiac Killer Ciphers

Zodiac 408 (solved, 1969)

BOT ORUD+DOYODASOW ZJGYKEDTYAABBLLD FBXAOXADONALIKO

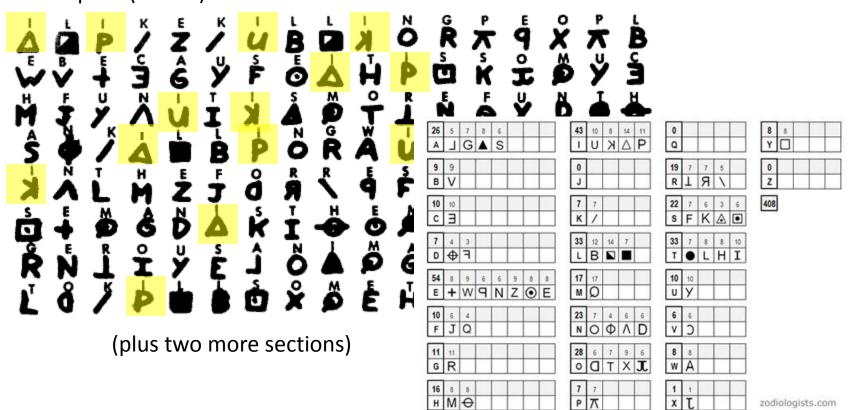


Zodiac 340 (still unsolved)



Zodiac Serial Killer

408-letter cipher (solved):



Zodiac Serial Killer

Plaintext solution

I LIKE KILLING PEOPLE BECAUSE IT IS SO MUCH FUN IT IS MORE FUN THAN KILLING WILD GAME IN THE FORREST BECAUSE MAN IS THE MOST DANGEROUE ANAMAL OF ALL TO KILL SOMETHING GIVES ME THE MOST THRILLING EXPERENCE IT IS EVEN BETTER THAN GETTING YOUR ROCKS OFF WITH A GIRL THE BEST PART OF IT IS THAE WHEN I DIE I WILL BE REBORN IN PARADICE AND THEI HAVE KILLED WILL BECOME MY SLAVES I WILL NOT GIVE YOU MY NAME BECAUSE YOU WILL TRY TO SLOI DOWN OR ATOP MY COLLECTIOG SLAVES FOR MY. **AFTERLIFE EBEORIETEMETHHPITI**

Plaintext has many misspellings

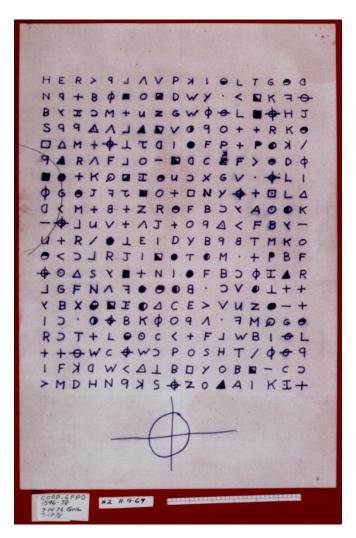
Final 18 plaintext characters of 408 are "junk"

Deciphering Zodiac 408 Bayesian models

Extended Carmel finite-state toolkit to do Bayesian inference. [Chiang et al 10]

Language Model	Initial Sample	Decipherment Error
3-gram	Random	62.3 / 48.5 / 47.4
5-gram	Random	all wrong!
u	3-gram solution	42.6
Word 1-gram	Random	all wrong!
Interpolated 5-gram and word 1-gram	Random	79.2
u	5-gram solution	3.3 / 2.6

Unsolved Zodiac 340



Has no obvious reading order bias:

% cipher bigram types that repeat (freq > 1)	Left/ Right order	Up/ Down order	Diag. North- East	Diag. South- East
Zodiac 408 (solved)	13 %	5	7	5
Zodiac 340 (unsolved)	7	6	8	5

Could be nonsense ... or maybe bigrams are smoothed out via more careful substitutions.